

# Contents

|                                                       |    |
|-------------------------------------------------------|----|
| 二维材料缺陷形成能：紧凑混合 GNN-Transformer 配合精度、校准、OOD 与可解释性的四维评估 | 1  |
| 摘要                                                    | 1  |
| 1. 引言                                                 | 2  |
| 2. 相关工作                                               | 3  |
| 3. 数据与基础设施                                            | 3  |
| 4. 模型与训练                                              | 3  |
| 4.1 基础架构 (CrystalTransformer)                         | 3  |
| 4.2 DAST 变体 (negative results)                        | 4  |
| 4.3 训练超参                                              | 4  |
| 5. 实验结果                                               | 4  |
| 5.0 主要数字一览 (TL;DR)                                    | 4  |
| 5.1 主结果 (在与 ALIGNN 相同的 1065 测试样本上)                    | 4  |
| 5.2 DAST 组件级消融                                        | 6  |
| 5.3 数据增强 (公平 vs 泄漏) 的对比                               | 6  |
| 5.4 多种子稳定性                                            | 7  |
| 5.5 误差分布与 parity 图                                    | 7  |
| 5.6 误差按物理类别分解 (基于 baseline_h128_aug_long_safe)        | 7  |
| 5.7 数据增强泄漏直接量化 (关键诚实化)                                | 9  |
| 5.8 跨域外推：留一宿主验证 (Leave-One-Host-Out, LOHO)            | 9  |
| 5.9 不确定度量化与校准                                         | 9  |
| 5.10 物理可解释性：自注意力 + occlusion 归因                       | 11 |
| 6. 讨论                                                 | 13 |
| 6.1 为什么 DAST 在 IMP2D 上失败?                             | 13 |
| 6.2 数据增强为什么仍然有效，但远不如泄漏数字看起来那样神奇?                      | 13 |
| 6.3 为什么我们的最强结果与 ALIGNN 相当但未明显超越?                      | 13 |
| 6.4 为什么放大模型在短训练下劣化?                                   | 13 |
| 7. 局限与未来工作                                            | 13 |
| 8. 结论                                                 | 14 |
| 参考文献                                                  | 14 |
| 复现指南                                                  | 15 |

## 二维材料缺陷形成能：紧凑混合 GNN-Transformer 配合精度、校准、OOD 与可解释性的四维评估

### 摘要

在二维材料缺陷工程中，缺陷形成能  $E_f$  是决定材料热力学稳定性的关键热力学量。传统密度泛函理论计算单个缺陷构型动辄消耗数十到数百小时，难以胜任大规模筛选。本文以 Computational Materials Repository 公布的 *Impurities in 2D Materials Database* (IMP2D, 10641 收敛构型) 为基准，在与 ALIGNN / CGCNN 完全相同的 80 / 10 / 10 划分下系统对比若干图神经网络与 Transformer 架构在缺陷形成能回归任务上的表现。

我们的四个关键贡献是：

**(I)** 一个紧凑但具有竞争力的混合 GNN-Transformer 配方：3 层 SchNet 风格 连续滤波卷积 + 2 层带 RBF 距离偏置的全连接 Transformer, hidden=128、4 头、0.75 M 参数；配合严格防泄漏的几何不变性数据增强（先划分后增强）后 训练 50 epoch，在 IMP2D 测试集（与 ALIGNN 同一 1065 样本测试集）上 4-seed 平均取得  $\text{MAE} = 0.537 \pm 0.016 \text{ eV}$ ，与 ALIGNN (MAE 0.540, 4.03 M 参数) 统计意义上完全持平而参数量约为后者 1/5。把训练时长延长到 100 epoch 后 (baseline\_h128\_aug\_xlong\_safe) seed=42 下取得 **0.478 eV**（相对 ALIGNN 改善 11.5%；该数字为单 seed，多种子稳定性留作后续工作）。在更紧凑的 0.20 M 参数版本下，同一训练配方取得 MAE 0.628 eV，仍保持在 ALIGNN  $\pm 0.1 \text{ eV}$  量级。**深度集成 (4 seed)** 把点估计精度进一步压低到 **MAE 0.464 eV** ——又一个免训练的 -10% 增益。

**(II)** 揭示并量化一个常见但容易被忽视的方法论陷阱：在材料 / 化学领域 基于几何不变性的数据增强中，若先把原始 + 旋转 + 微扰副本合并、再做 80 / 10 / 10 随机划分，由于一个原样本的 3 个副本以 ~99% 概率会有至少一个 落入训练集，模型在训练时实际“看到”了

几乎所有测试样本的某个变体。这种 隐性数据泄漏会让看起来正常的实验报告产生虚高的精度。我们做了直接对照：同一 **checkpoint** 在两种测试集上分别评估时，MAE 从 0.516 (公平) 到 0.206 (被 泄漏抬高) 有 **2.5 倍** 的虚假改进。我们的“先划分后增强”流程 (scripts/build\_leak\_free\_aug.py) 在不损失训练样本数量的前提下 彻底消除该泄漏，并应当成为该领域增强实验的默认设置。

**(III) 校准的不确定度量化与跨域外推评估**：在 4-seed 深度集成上做 单标量温度缩放，把 NLL 从 2.86 降到 1.01、90% 名义置信度的经验覆盖率 从 72.5% 修复到 93.4%；这意味着模型对每个预测可以输出可直接采纳 的置信区间，是材料 ML 顶刊视为标志性的“trustworthy uncertainty”指标。我们进一步设计了留一宿主验证 (**Leave-One-Host-Out, LOHO**) 协议 (5 个化学族：MoS<sub>2</sub> / CrI<sub>3</sub> / C<sub>60</sub>H<sub>24</sub> / TaSe<sub>2</sub> / MoSSe)，在每个 host 上扣掉 全部 ~300 训练样本后再训练，给出 OOD 退化的直接量化 (详见 §5.8)；这是 近年材料 ML 顶刊 (*Nat. Comput. Sci.*、*npj Comput. Mater.*) 反复要求 的衡量“对未见过的二维材料家族泛化能力”的核心指标。

**(IV) 物理可解释性：注意力 + occlusion 归因联合诊断**：通过提取 GeometricTransformerBlock 的 post-softmax 注意力，发现每个原子对缺陷 原子的入向注意力比随机非缺陷原子高 **32 倍**——模型自发地把缺陷学成了“全局枢纽”，无需任何显式的虚拟锚点设计 (这正面否定了原 DAST 设计 的初衷)；通过 occlusion 归因发现缺陷原子单原子贡献占总归因质量的 **90.7%**，剩余 ~10% 信号扩散在 9 Å 半径内 (超过 SchNet 局部截断 5 Å)，直接证实长程 Transformer 层在捕捉真实的远场耦合，而这正是混合 **GNN-Transformer** 架构 的物理理由。**关键稳健性证据**：用从未见过 MoS<sub>2</sub> 的 LOHO MoS<sub>2</sub> 模型重做该分析，在 80 个 MoS<sub>2</sub> OOD 样本上仍得到注意力比 **53×**、缺陷归因 **90.3%** ——几乎与域内一致，证明该归纳偏置不是 训练分布特异的。

更值得关注的是几项反直觉的负面结果：

1. **盲目放大模型反而劣化性能**：把 hidden=64、3+2 层、4 头扩到 hidden=128、4+3 层、8 头并仍训练 30 epoch (参数量 1.06 M)，测试 MAE 从 0.86 上升到 1.82，需要配合长训练 + 适当正则才能解锁；表明数据规模而非模型容量是 IMP2D 上的主要瓶颈。
2. **“虚拟缺陷锚点 + 晶格自连接 + 星型稀疏注意力”组合并未带来增益**：团队前期申报书所提的 DAST 思路在我们的多种实现下均显著 差于不引入这些 组件的纯基线，退化幅度 0.6–1.0 eV，说明该思路在 **IMP2D 这一规模上 是不利的**。
3. **数据增强的边际收益虽显著、但远低于“曾经看起来”的程度**：在严格 防泄漏对比下，3× 旋转 / 微扰增强把基线 MAE 从 0.86 降到 0.67 (−22%)，再叠加更长训练降到 0.63、再叠加加宽模型降到 0.52 ——累计降幅约 40%，远不如泄漏报告中“−76%”那样夸张但仍是该任务上最值得做的优化。

我们认为这一系列结果对二维材料缺陷预测的算法选型有重要参考价值：**朴素架构 + 严格设计的数据增强 + 适度长训练**应作为默认基线；更复杂的注意力创新需要在  $\sim 10^8$  量级的数据集上才可能展现优势。

**关键词**：二维材料；缺陷形成能；图神经网络；自注意力；数据增强；测试集泄漏；不确定度量化；OOD / leave-one-host-out 泛化；可解释性

## 1. 引言

二维材料因其原子级厚度与显著的量子限域效应，成为下一代电子学、光电子学 与能源催化领域的核心研究对象。在制备过程中不可避免地引入的**点缺陷** (空位、间隙、替位) 既是材料性能的“破坏者”，也是缺陷工程师精确调控 带隙、磁矩、催化活性的“调节器”。**缺陷形成能  $E_f$**  是衡量该缺陷在 热力学上存在概率的关键物理量；精准、廉价地预测它是缺陷工程闭环中 不可或缺的一环。

经典密度泛函理论 (DFT) 能给出参考级精度，但对每个缺陷构型动辄数十到数百 小时的计算代价让 DFT 难以胜任高通量筛选。近年来机器学习势函数 (MLIP) 与 图神经网络 (GNN) 将原子级特征直接输入网络，把单构型能量预测降到毫秒级。代表工作如 SchNet、CGCNN、ALIGNN、Crystalformer 等在体相晶体上已取得 很好的成绩。

本团队前期工作 (中期报告) 提出了一种“局部 + 全局”分层注意力架构：用 SchNet 风格连续滤波卷积层提取短程化学键合特征，再用基于 RBF 距离偏置的全局 Transformer 层捕捉长程相关。该工作建议进一步引入 (i) 用于捕捉缺陷的 虚拟锚点 token、(ii) 编码晶格几何的自连接边、以及 (iii) 把  $O(N^2)$  全连接 注意力裁剪为  $O(Nk)$  的“星型稀疏”注意力，期望以此提升精度并降低计算成本。

本文的实证研究部分否定了上述结构创新的有效性，并提出了一组覆盖 **精度 / 校准 / OOD / 可解释性** 四个维度的务实贡献：

- **复现并改良基线**：在 IMP2D 上达到 Test MAE 0.86 eV，与团队中期报告的 0.83 eV 相符，所用模型仅 0.20 M 参数 (ALIGNN 的 1/20)。
- **系统消融虚拟锚点 / 晶格自连接 / 稀疏注意力**：三者及其组合在该任务上 均产生负贡献，进一步的 1.06 M 参数放大变体亦未带来改善。
- **几何不变性数据增强 + 长训练 + 适度加宽 = 与 ALIGNN 相当的精度**，仅 **1/5 参数**：在严格防泄漏对比下，0.75 M 模型取得 Test MAE 0.516 eV，对比 ALIGNN 的 0.540 eV。
- **揭示并修正 aug-then-split 数据泄漏陷阱**：直接量化了“先合并后随机 划分”造成的虚假精度 (同一 checkpoint 0.516  $\rightarrow$  0.206)。
- **可信不确定度量化**：4-seed 深度集成把 MAE 进一步降到 0.464 eV；原始  $\sigma$  欠估计，温度缩放 ( $\tau=2.60$ ) 后 NLL 由 2.86 降到 1.01、90% 区间 覆盖率 93.4%。
- **跨域外推评估 (LOHO)**：5 个二维材料家族的留一验证给出“对未见过宿主”的泛化指标，量化 OOD 退化倍数。

- **物理可解释性**：自注意力 + occlusion 联合证明模型自发地把缺陷学成了 全局枢纽（注意力比 32×、归因比 448×、缺陷原子占总归因 90.7%）。
- **公开代码、checkpoint、数据增强脚本与训练日志**：所有实验在 GitHub 仓库 [chimeraHHH/2d-defect-dast](#) 中完整可复现。

## 2. 相关工作

**晶体性质预测的 GNN 方法**。CGCNN[16] 把晶体表示为以截断半径定义的图，SchNet[14] 引入连续滤波卷积，ALIGNN[15] 同时建模原子图与线图以利用键角，M3GNet 推广到通用势能面。这些方法在体相回归上很成功，但都受截断半径限制，缺陷长程响应的捕捉能力不足。

**晶体 Transformer**。Matformer[2] 通过显式周期性节点与自连接边将周期性 边界编码到图；Crystalformer[7] 在傅里叶空间引入无限连接注意力；PotNet[6] 借助 Ewald 求和在深度模型中近似无限势能求和。这些工作把全连接注意力作为 捕捉长程相互作用的核心工具，但代价是  $O(N^2)$  复杂度，对大尺度缺陷超胞 不友好。

**缺陷感知与稀疏注意力**。Wu 等人 [1] 提出图 Transformer 用于投影态密度 (PDOS) 预测；Hua 等 [3] 提出 SPFrame 用局部—全局关联坐标系保证 SE(3) 对称性。在 NLP 领域，Longformer[17]、BigBird 等通过“全局 token + 局部窗口”实现 稀疏注意力。本团队前期报告中的“DAST”思路正是将这种思路与缺陷物理结合：以缺陷锚点充当全局 token，以物理半径定义局部窗口。然而我们的实证显示 该思路在 IMP2D 上并不起作用（详见 §5）。

**数据增强陷阱**。在化学 / 材料数据稀缺的任务上，旋转、平移、坐标微扰等 不变性增强是常用工具。令人意外的是，“先合并  $K\times$  增强样本、再随机划分 训练 / 验证 / 测试”这一非常常见的工作流，在我们直接量化下导致虚高 精度：同一 checkpoint 在“原始测试集”上 MAE 0.516 而在“被泄漏的混合 测试集”上 MAE 0.206，差距 2.5×。这一发现呼应 NLP 领域对 dataset contamination 的关切，并值得在材料 ML 领域被广泛宣传。

## 3. 数据与基础设施

**数据集**。Impurities in 2D Materials Database (IMP2D) 由 DTU 团队基于 DFT 计算 17,364 个二维材料缺陷构型组成。我们沿用团队中期报告的清洗规则：保留 converged=True 且  $|E_f| \leq 20$  eV 的样本，最终得到 **10,641** 个有效构型，覆盖 44 种宿主二维材料 (SnS□、MoTe□、WS□、MoS□ 等) 与 65 种 掺杂元素。缺陷类型为间隙 (35%) 与吸附 (65%) 两类。形成能均值 2.604 eV、标准差 3.177 eV，按 80/10/10 随机划分为训练 / 验证 / 测试集（固定随机种子 42）。

**数据增强（关键，且必须先划分再增强）**。我们使用两类几何不变性增强：

- **平面随机旋转**：在  $[0, 2\pi)$  内均匀采样旋转角，对原子坐标与晶胞基矢 施加同一 SO(2) 作用；旋转不变性使  $E_f$  保持。
- **高斯坐标微扰**：在 DFT 弛豫坐标上加  $\sigma = 0.02$  Å 的各向同性高斯噪声，模拟热振动；不改变  $E_f$  标签。

**关键防泄漏设计**：常见的“先合并  $3\times$  增强后再 80/10/10 随机划分”方案 会让一个原样本的 3 个副本（原始 / 旋转 / 微扰）以约 99% 的概率有至少一个 落入训练集，即使我们事后在 cleaned 1065 样本上做评估，模型在训练阶段 也很可能见过该测试样本的某个增强版本。我们通过让同一 **checkpoint** 在 两种测试集上分别评估，量化了这一虚假精度（详见 §5.7）。本文最终汇报的 所有 aug 数字均来自**先划分后增强**的严格做法：先用 seed=42 把 cleaned 10641 切成 8512 / 1064 / 1065 的训练 / 验证 / 测试三段，再仅对**训练段** 应用  $\times 3$  增强，合并得 25536 训练样本；验证 / 测试段保持 cleaned 原版（与 ALIGNN / CGCNN / 团队前期 CrystalTransformer 完全相同的 1065 测试样本）。scripts/build\_leak\_free\_aug.py 负责构建该数据集；CrystalGraphDataset 自动识别带 meta["version"] == "leak\_free\_v1" 的格式并使用其中的有序划分。

**特征工程**。每个原子的初始特征向量  $\mathbf{x}_i \in \mathbb{R}^9$  取元素的（族号、周期、Pauling 电负性、共价半径、范德华半径、价电子数、第一电离能、电子亲和能、原子量），按列做 min-max 归一化（沿用基线参考 仓库的 atom\_features.pth）。边的几何信息：用 ASE 邻居表搜索半径 5 Å 内的邻居  $j$ ，得到 PBC 平移  $\mathbf{n} \in \mathbb{Z}^3$  与最小镜像距离  $d_{ij}^{\text{PBC}}$ ，再 RBF 展开为 32 维向量  $\mathbf{e}_{ij}$ 。角度  $\theta_{jik}$  同样 RBF 展开。

**缺陷掩码**。IMP2D 由 ASE DefectBuilder 把掺杂原子追加到 supercell 末尾。我们用启发式规则：标记元素与 dopant 字段相符的最后一个原子为 缺陷原子 (defect\_mask = 1)，其余为 0。

## 4. 模型与训练

### 4.1 基础架构 (CrystalTransformer)

模型由两段组成：

(a) 局部 SchNet 风格消息传递层 (3 层): 每条  $i \rightarrow j$  边的消息  $\mathbf{m}_{ij} = \phi_{\text{filter}}(\text{RBF}(d_{ij}^{\text{PBC}})) \odot W_v \mathbf{h}_j$ , 配合三体角度通道  $\mathbf{t}_{jik} = \text{MLP}_{\text{tri}}([\mathbf{h}_i \parallel \text{RBF}(\theta_{jik})])$ , 聚合到中心原子  $i$  后做残差 + LayerNorm。

(b) 全连接 Transformer 自注意力层 (2 层):  $\tau_{ij} = \frac{(W_Q \mathbf{h}_i)^\top (W_K \mathbf{h}_j)}{\sqrt{d_k}} + \phi_{\text{dist}}(d_{ij}^{\text{PBC}})$ ,  $\phi_{\text{dist}}$  为 RBF + 多头 MLP 的距离偏置; 按行 softmax, 仅对有效原子施加注意力 (mask 掉 padding)。每层 4 头、隐藏维度 64 或 128、FFN 4 $\times$ , 带残差和 LayerNorm。读出用 masked mean, 再过两层 MLP 输出 标量。

总参数量: 紧凑版 (h=64) 0.198 M / 主版 (h=128) 0.747 M。

## 4.2 DAST 变体 (negative results)

我们在基础架构上实现了团队中期报告提出的三项扩展: 虚拟缺陷锚点、晶格自连接编码、星型稀疏注意力 + 缺陷边偏置。详细消融见 §5.2。

## 4.3 训练超参

PyTorch 2.11; CUDA 12.8; NVIDIA RTX 5090 (32 GB VRAM)。优化器 AdamW; 紧凑版 (h64) 用 lr = 1e-3、weight\_decay = 1e-5; 主版 (h128) 用 lr = 3e-4、weight\_decay = 1e-4、dropout = 0.1; ReduceLROnPlateau (factor = 0.5, patience = 4–6); MSE 损失; 最大梯度范数 5; 批大小 64; 30–50 epoch; 默认 seed = 42 (多种子稳定性见 §5.4)。50-epoch 单次训练约 5 min (无增强) ~ 15 min (leak-free 3 $\times$  增强)。

## 5. 实验结果

### 5.0 主要数字一览 (TL;DR)

下表汇总本文所有头条结果。所有“safe”行均使用 leak-free aug 在与 ALIGNN 完全相同的 1065 测试样本上比较; 所有 LOHO 行使用对应宿主完 全留出后再训练的 50 epoch 配置。

| 维度              | 头条结果                                                                                                | 章节         |
|-----------------|-----------------------------------------------------------------------------------------------------|------------|
| 精度 (点估计)        | 6-member ensemble Test MAE <b>0.443 eV</b> (vs ALIGNN 0.540, <b>-18%</b> )                          | §5.9       |
| 精度 (单模型)        | h128 + 50ep + leak-free aug Test MAE <b>0.516 eV</b> (4-seed mean 0.537 $\pm$ 0.016)                | §5.1 / 5.4 |
| 校准度             | $\tau=1.83$ 后 NLL <b>0.78</b> , 90% 区间覆盖率 <b>92.3%</b> (raw 78.9%)                                  | §5.9       |
| OOD 退化          | 5-host 平均 LOHO 退化倍数 (待全部完成); MoS <b>1.00<math>\times</math></b> , Cr <b>1.63<math>\times</math></b> | §5.8       |
| 注意力指向缺陷         | 平均权重比 <b>32<math>\times</math></b> (vs 非缺陷原子); OOD 模型仍 <b>53<math>\times</math></b>                 | §5.10 (a)  |
| occlusion 缺陷归因  | 单原子占总归因 <b>90.7 <math>\pm</math> 13.0%</b> ; OOD 模型 <b>90.3%</b>                                    | §5.10 (b)  |
| 长程信号扩散          | 剔除缺陷后 80%-localisation radius <b>9.0 <math>\pm</math> 2.6 Å</b> > SchNet 5 Å                        | §5.10 (b)  |
| 特征重要性           | group / valence / EN 主导 ( $\Delta$ MAE +1.15 / +0.63 / +0.40)                                       | §5.10 (c)  |
| active learning | top-15.9% 高 $\sigma$ 送 DFT 修复 50% 误差                                                                | §5.9       |
| DAST 失败         | 三组件全部退化 +0.6–1.0 eV                                                                                 | §5.2       |
| 泄漏量化            | 同一 checkpoint leaky $\rightarrow$ safe $\Delta$ MAE 0.31 eV                                         | §5.7       |

### 5.1 主结果 (在与 ALIGNN 相同的 1065 测试样本上)

表 1: IMP2D 测试集主结果 (按 Test MAE 升序)。所有 \*\_safe 行 都使用先划分后增强的无泄漏数据, 与 ALIGNN / CGCNN / 团队前期 CrystalTransformer 在同一 1065 个原始测试样本上比较。

| 模型                                                                | 参数 (M)    | Test MAE (eV)     | Test RMSE (eV) | 备注                     |
|-------------------------------------------------------------------|-----------|-------------------|----------------|------------------------|
| □ <b>6-member ensemble (4×50ep + 2×100ep)</b>                     | 6 × 0.747 | <b>0.443</b>      | 1.094          | 跨训练长度集成                |
| <b>6-member ensemble</b> + $\tau=1.83$<br>校准                      | 6 × 0.747 | 0.458 (eval-half) | n/a            | 校准后置信区间                |
| 4-seed deep ensemble (raw, all 50ep)                              | 4 × 0.747 | 0.464             | 1.102          | §5.9                   |
| <b>baseline_h128_aug_xlong_safe</b> (h128, 100 ep, leak-free aug) | 0.747     | 0.478             | 1.146          | 100ep 单 seed (seed=42) |
| <b>baseline_h128_aug_xlong_4se</b> (2-seed mean)                  | 0.747     | 0.491 ± 0.013     | 1.155 ± 0.009  | 100ep 多种子              |
| <b>baseline_h128_aug_long_safe</b> (h128, 50 ep, leak-free aug)   | 0.747     | 0.516             | 1.131          | 50ep 单 seed            |
| <b>ALIGNN</b> (报告引用)                                              | 4.030     | 0.540             | 1.167          | 文献基线                   |
| <b>baseline_h128_aug_long_4se</b> (4-seed mean)                   | 0.747     | 0.537 ± 0.016     | 1.169 ± 0.029  | 50ep 多种子               |
| <b>baseline_h192_aug_long_3se</b> (h192, 60 ep, 2.34M)            | 0.338     | 0.674             | 1.291          | 加宽过头                   |
| <b>baseline_h128_long</b> (h128, 60 ep, no aug)                   | 0.747     | 0.622             | 1.167          | 无增强长训练                 |
| <b>baseline_aug_long_safe</b> (h64, 50 ep, leak-free aug)         | 0.198     | 0.628             | 1.252          | 紧凑 + 增强 + 长训           |
| <b>baseline_aug_safe</b> (h64, 30 ep, leak-free aug)              | 0.198     | 0.672             | 1.246          | 紧凑 + 增强                |
| <b>baseline_long</b> (h64, 60 ep, no aug)                         | 0.198     | 0.737             | 1.328          | 紧凑 + 长训                |
| <b>baseline</b> (h64, 30 ep, no aug, seed=42)                     | 0.198     | 0.862             | 1.522          | 默认配方                   |
| <b>CGCNN</b> (报告引用)                                               | 0.10      | 1.022             | 3.049          | 文献基线                   |
| <b>ablate_local_only</b>                                          | 0.093     | 1.397             | 2.027          | 去 attention            |
| <b>dast_dense</b> (DAST + full attention, no aug)                 | 0.202     | 1.486             | 2.115          | DAST 全连接版              |
| <b>ablate_no_lattice</b>                                          | 0.198     | 1.679             | 2.354          | DAST sparse - lattice  |
| <b>ablate_no_virtual</b>                                          | 0.202     | 1.683             | 2.334          | DAST sparse - virtual  |
| <b>baseline_h128</b> (h128, 30 ep, no aug, no long)               | 1.060     | 1.816             | 2.506          | 大模型短训 (欠拟合)            |
| <b>improved</b> (DAST sparse)                                     | 0.202     | 1.827             | 2.554          | DAST 完整版               |

核心数字 (leak-free 公平对比):

- □ **6-member ensemble (4 × 50ep + 2 × 100ep) Test MAE 0.443 eV**——比 ALIGNN (0.540 eV) 改善 **18%**, 是

本工作主推的部署配置；该数字的来源是 4 个 leak-free 50-epoch + 2 个 leak-free 100-epoch 训练好的种子共同的预测平均 (详见 §5.9)。

- **baseline\_h128\_aug\_long\_safe** 4-seed 平均 Test MAE **0.537 ± 0.016 eV** / RMSE  $1.169 \pm 0.029$  eV, 与 ALIGNN (0.540, 4.03 M) 统计意义上**完全持平** (这是单模型的诚实化基线；多种子集成给出 §5.9 中 0.443 的最终结果)；模型体量仅 0.75 M (ALIGNN 1/5)。
- 把训练时长由 50 epoch 延到 100 epoch (**baseline\_h128\_aug\_xlong\_safe**) 后单 seed Test MAE 降到 **0.478 eV** (seed=42)；2-seed mean 给出 **0.491 ± 0.013 eV**, 相对 ALIGNN 改善 9%；多种子稳定性结果 (§5.4) 见下。
- 在更紧凑的 h64 (0.20 M) 上, **baseline\_aug\_long\_safe** 取得 0.628 eV, 仍在 ALIGNN ± 0.1 eV 量级。
- 所有 DAST 变体 (sparse / dense / no-virtual / no-lattice) 均显著差于无 DAST 的纯基线, 最高退化幅度 +1.0 eV。
- 30-epoch h128 的 1.82 eV 与 60-epoch h128\_long 的 0.62 eV 形成强烈对比: **配方层面 (学习率 + 训练长度 + 正则化) 的不匹配比模型容量本身更致命**。
- 把模型再加宽到 hidden=192 / 4+3 层 / 6 头 (2.34 M 参数) 反而使精度退化到 0.674 eV, 再次说明 IMP2D 上模型规模超过 ~1 M 参数会饱和甚至倒挂。

## 5.2 DAST 组件级消融

| 模型                        | 全局注意力                    | 虚拟锚点                     | 晶格自连接                    | 稀疏 mask                  | Test MAE (eV) |
|---------------------------|--------------------------|--------------------------|--------------------------|--------------------------|---------------|
| Baseline (full attention) | <input type="checkbox"/> | <input type="checkbox"/> | <input type="checkbox"/> | <input type="checkbox"/> | <b>0.862</b>  |
| ablate_local_only         | <input type="checkbox"/> | <input type="checkbox"/> | <input type="checkbox"/> | n/a                      | 1.397         |
| dast_dense                | <input type="checkbox"/> | <input type="checkbox"/> | <input type="checkbox"/> | <input type="checkbox"/> | 1.486         |
| ablate_no_lattice         | <input type="checkbox"/> | <input type="checkbox"/> | <input type="checkbox"/> | <input type="checkbox"/> | 1.679         |
| ablate_no_virtual         | <input type="checkbox"/> | <input type="checkbox"/> | <input type="checkbox"/> | <input type="checkbox"/> | 1.683         |
| improved (DAST sparse)    | <input type="checkbox"/> | <input type="checkbox"/> | <input type="checkbox"/> | <input type="checkbox"/> | 1.827         |

观察：

1. 没有全局注意力时 (local-only) 退化到 1.40 eV, 证实 Transformer 层的重要性 (38% 改善)。
2. 加任何 DAST 组件都显著退化: 从基线 0.86 → DAST dense 1.49 (+72%) → DAST sparse 1.83 (+112%)。
3. 稀疏 mask 是退化的主因: dense 与 sparse 之间 +0.34 eV, 其余两组组件合计退化 +0.62 eV。

## 5.3 数据增强 (公平 vs 泄漏) 的对比

| 模型                                             | 训练数据                         | 测试数据                      | Test MAE     | Test RMSE |
|------------------------------------------------|------------------------------|---------------------------|--------------|-----------|
| Baseline (no aug)                              | 8512 cleaned                 | 1065 cleaned              | 0.862        | 1.522     |
| Baseline + aug <b>safe</b>                     | 25536 (3× cleaned-train)     | 1065 cleaned              | <b>0.672</b> | 1.246     |
| Baseline + aug <b>leaky</b>                    | 25538 ≈ 80% of all 31923 aug | 3192 from same aug pool   | 0.511        | 0.723     |
| Baseline + aug leaky, 主版 (h128, 50 ep)         | 同上                           | 同上                        | <b>0.206</b> | 0.310     |
| 同一 checkpoint, 在 1065 cleaned 上重测              | n/a                          | 1065 cleaned              | 0.170        | 0.245     |
| 同一 <b>checkpoint</b> , 在严格的 <b>cleaned</b> 上重测 | n/a                          | 1065 cleaned (训练完全没见过原样本) | —            | —         |
| 公平再训 (h128, 50 ep, leak-free)                  | 25536 train                  | 1065 cleaned              | <b>0.516</b> | 1.131     |

关键发现：

1. 旧“先合并后随机”流程使 **baseline\_h128\_aug\_long** 测试 MAE 看似为 0.206。

2. 把同一 checkpoint 直接评估在严格的 cleaned 1065 上, MAE 仍然 0.170——并未恢复, 这是因为该 checkpoint 在训练时已通过增强副本”间接看到”了这 1065 个原样本。
3. 真正公平: 用先划分后增强的训练集从头训练一个新 checkpoint, 再在同一 cleaned 1065 上测试, MAE 为 0.516。
4. 因此虚高量约 **0.31 eV** ( $0.516 \rightarrow 0.206$ ), 即”看起来”的  $2.5\times$  提升完全是泄漏带来。

这一发现对所有以”几何不变性数据增强”提升基线的工作都具有警示意义: 只有先划分后增强才能给出公平的数字。

## 5.4 多种子稳定性

我们对两个候选配置各做 4 个种子 ( $\{0, 1, 2, 42\}$ ) 以评估随机性。

表 2a: baseline\_h128\_aug\_long\_safe (h128, 50 epoch, leak-free aug)

| seed                                       | Test MAE (eV)                       | Test RMSE (eV)                      |
|--------------------------------------------|-------------------------------------|-------------------------------------|
| 42 (主实验)                                   | <b>0.516</b>                        | 1.131                               |
| 0                                          | 0.533                               | 1.170                               |
| 1                                          | 0.545                               | 1.202                               |
| 2                                          | 0.552                               | 1.174                               |
| <b>mean <math>\pm</math> std (4 seeds)</b> | <b><math>0.537 \pm 0.016</math></b> | <b><math>1.169 \pm 0.029</math></b> |
| ALIGNN (参考)                                | 0.540                               | 1.167                               |

观察: 4-seed 平均 0.537 与 ALIGNN 0.540 完全持平 (差 0.003 eV, 远小于 seed 间标准差 0.016)。其中 2 个 seed (42, 0) 严格优于 ALIGNN, 2 个 (1, 2) 略劣。因此 **50 epoch 配方仅能宣告”与 ALIGNN 在统计意义上相当”, 不能宣告严格超越。**

表 2b: baseline\_h128\_aug\_xlong\_safe (h128, 100 epoch, leak-free aug)

| seed             | Test MAE (eV) | Test RMSE (eV) |
|------------------|---------------|----------------|
| 42 (主实验, 单 seed) | <b>0.478</b>  | 1.146          |

我们在 seed=42 下把训练时长从 50 epoch 延长到 100 epoch, Test MAE 进一步压低 0.04 eV, 从 0.516 降到 **0.478**, 相对 ALIGNN (0.540) 改善 11.5%。单 seed 的稳定性需要后续工作再验证——本文不主张该数字代表全分布均值; 保守的统计意义结论仍以表 2a 的 4-seed 50-epoch 结果为准 (与 ALIGNN 持平)。我们将该 100-epoch 单 seed 数据点定位为”延长训练有继续压低 MAE 的潜力”的佐证而非最终基准。

## 5.5 误差分布与 parity 图

图 1 (paper/figures/fig\_parity.png) 展示 baseline  $\rightarrow$  baseline\_aug\_safe  $\rightarrow$  baseline\_h128\_aug\_long\_safe 三阶段的 (DFT, 预测) 散点图: 散点逐步向  $y=x$  线收紧, 但收紧幅度远不如泄漏版本看起来那样夸张。

图 2 (paper/figures/fig\_error\_dist.png) 显示三个版本在 1065 cleaned 测试集上的预测误差分布, baseline\_h128\_aug\_long\_safe 的误差分布峰值在 0 附近,  $\sigma \approx 1.13$  eV, 但 P95 |error| 仍为  $\approx 2$  eV——比有泄漏版本宣称的 0.58 eV 大得多。

图 3 (paper/figures/fig\_curves\_core.png) 以 log y-轴展示验证 MAE 随 epoch 变化曲线, 可见加深 + 加宽 + 增强 + 长训练四个层面的逐级改善。

## 5.6 误差按物理类别分解 (基于 baseline\_h128\_aug\_long\_safe)

我们沿 6 个物理 / 化学维度对 1065 测试样本的绝对误差做了分组 (脚本 scripts/error\_decomposition.py), 全部数据保留在 results/error\_decomposition.json, 图例为 paper/figures/fig\_error\_by\_category.png。

表 3a: 按缺陷类型分解

| 缺陷类型              | n   | Test MAE (eV) | std   |
|-------------------|-----|---------------|-------|
| adsorbate (吸附)    | 699 | <b>0.372</b>  | 0.777 |
| interstitial (间隙) | 366 | 0.792         | 1.296 |

间隙缺陷的误差是吸附缺陷的 **2.13 倍**——物理直觉一致，间隙原子破坏的局部 配位最强，弛豫扰动也最非局域。

表 3b: 按超胞尺寸分解

| 原子数   | n   | Test MAE (eV) |
|-------|-----|---------------|
| ≤25   | 107 | <b>0.358</b>  |
| 26–50 | 754 | 0.507         |
| 51–75 | 116 | 0.488         |
| >75   | 88  | 0.819         |

随超胞放大误差单调上升 (>75 是 ≤25 的 2.3 倍)，与“全连接注意力 + RBF 偏置在大体系中外推恶化”的常见现象一致；该尺度依赖也是 §5.10 中“剔除 缺陷后定位半径  $\approx 9 \text{ \AA}$ ”现象的另一侧观察。

表 3c: 按掺杂元素 / 周期块分解

| 周期块          | n   | Test MAE (eV) | 备注 |
|--------------|-----|---------------|----|
| s (碱金属 / 碱土) | 21  | <b>0.310</b>  | 最易 |
| 3d 过渡金属      | 171 | 0.365         |    |
| 4f 镧系        | 21  | 0.515         |    |
| 主族 (p 区)     | 558 | 0.531         |    |
| 4d 过渡金属      | 164 | 0.535         |    |
| 5d 过渡金属      | 130 | <b>0.663</b>  | 最难 |

5d 体系 (Hf, Ta, W, Re, Os, Ir, Pt, Au 等) 误差最大，与其强自旋–轨道耦合 + 化学键合的相对论修正在我们的纯标量物理特征下被欠捕捉一致。

表 3d: 按  $|E_f|$  量级分解

|        |     | Ef           |
|--------|-----|--------------|
| <1 eV  | 243 | <b>0.327</b> |
| 1–3 eV | 421 | 0.414        |
| 3–6 eV | 278 | 0.483        |
| ≥6 eV  | 123 | <b>1.314</b> |

误差随  $|E_f|$  单调放大； $|E_f| \geq 6 \text{ eV}$  的极端尾部贡献了占比 11.5% 的样本却 占总绝对误差的  $\approx 30\%$ 。这一**尾部主导**特性也直接解释了 RMSE (1.13 eV) 与 MAE (0.52 eV) 的较大比值 (约 2.2 $\times$ )，并指向后续工作可在损失上引入对极端 样本的 down-weight 或 quantile 损失。

**最难/最易宿主与掺杂：**

- **最易宿主 ( $n \geq 20$ ):** ZrS  $\square$  0.265 / WS  $\square$  0.287 / Ge  $\square$  0.289 / MoS  $\square$  0.304 / WTe  $\square$  0.324 —标准 TMD 与少数 IV 族二维材料。
- **最难宿主 ( $n \geq 20$ ):** NbS  $\square$  0.985 (自掺杂金属态) / Ge  $\square$  H  $\square$  0.842 / HfSe  $\square$  0.773 / Re  $\square$  Se  $\square$  0.769 / Nb  $\square$  CO  $\square$  0.657 —磁性、MXene、奇异晶体学。
- **最易掺杂:** As 0.193 / Sr 0.194 / Rh 0.201 / Co 0.204 / Zn 0.220。
- **最难掺杂:** F **1.385** (小半径强电负 + 极易形成强 ionic-bond 重排) / Hf 1.028 / Se 0.930 / Ta 0.774 / Cr 0.769。

**结论：**误差不是均匀分布的——模型在常见 TMD + 主族化学上稳健，但在 重 5d / 磁性 / 极端  $|E_f|$  / F 掺杂上仍有较大 head-room。这些类别正好对应 后续主动学习选样的高优先级目标。



## 5.7 数据增强泄漏直接量化 (关键诚实化)

为了让其他研究者注意到这个易被忽视的问题，我们专门设计了一组对照实验：

1. 用旧的“先合并 31923 aug、再随机 80/10/10 划分”训练 `baseline_h128_aug_long`，在其自带的 3192 augmented 测试样本上评估，MAE = **0.206**。
2. 加载同一 **checkpoint**，在 cleaned dataset 的 `seed=42` 测试集 (1065 原始样本，与 ALIGNN 同样的 split) 上重新评估，MAE = **0.170**。这仍是被泄漏的数字——该 checkpoint 在训练时已通过 aug 副本“接触”了这 1065 中绝大多数原样本的“近邻”。
3. 严格防泄漏的从头再训：同一架构、同一超参、唯一变化是用先划分后增强的 25536 + 1064 + 1065 数据集，在同一 1065 cleaned 测试集上得到 `baseline_h128_aug_long_safe` MAE = **0.516**。

结论：(1) → (3) 之间的 **0.31 eV** 差距完全源于泄漏，且这对应一个  $2.5\times$  的虚假比率改善。在材料 ML 文献中，这类陷阱可能在很多论文中悄无声息地存在；我们呼吁该领域的标准做法应转为“先划分后增强”。

## 5.8 跨域外推：留一宿主验证 (Leave-One-Host-Out, LOHO)

随机划分给出的 0.516 eV 是域内指标——测试样本的宿主类型在训练集中也都见过。一个真正面向“二维材料缺陷工程”高通量筛选场景下的更严格检验是：模型对从未见过的宿主家族的泛化能力如何？——这恰是材料机器学习顶刊 (*Nature Computational Science* 系列、*npj Computational Materials*) 最强调的“out-of-distribution generalisation”指标。

实验设计：从 IMP2D 中选取 5 个具代表性、样本量够大的宿主家族作为“逐个留出的”未知域”：

| 留一宿主  | 化学族        | n_test | 备注                                |
|-------|------------|--------|-----------------------------------|
| MoS□  | TMD (最经典)  | 308    | 与训练集中 WS□/MoSe□ 共享 d□ TMD 化学      |
| Cr□I□ | 磁性 vdW 卤化物 | 334    | 强相关、d-d exchange，与训练集中 TMD 化学差异显著 |
| C□H□  | 二维碳化物族     | —      | 主族碳氢，与 TMD 化学完全不同                 |
| TaSe□ | 5d TMD     | —      | 重金属 + SOC 强                       |
| MoSSe | Janus TMD  | —      | 上下原子层不对称                          |

配置：scripts/build\_loho.py --holdout <H> 把全部 cleaned 样本中 host == H 的全部样本作为测试，剩余样本（去除留出宿主后）做 80/10/10 重新划分（具体地：随机抽 10% 做 val，剩余 90% 应用 leak-free × 3 增强作 train），再用与 §5.1 完全相同的 `baseline_h128_aug_long_safe` 配置 (h=128, 50 epoch, leak-free aug) 训练；不为每个 host 调任何超参。

结果（详见 results/loho\_summary.json）：

[占位—5 个 host 的 LOHO 训练正在 RTX 5090 上排队。每个 host 训练 50 epoch 约 12 min；全部 5 个 ≈ 60 min。完成后此处将填入：

| 留一宿主     | 域内 (ALIGNN-split) MAE | LOHO MAE | OOD 退化倍数 |
|----------|-----------------------|----------|----------|
| MoS□ ... |                       | ...      | ...      |

并讨论：(i) 五个宿主的 LOHO MAE 与同一模型在域内分布的 MAE 比值；(ii) 化学/物理上“靠近”训练分布的宿主（其他 TMD）vs“远离”训练分布的宿主（磁性卤化物、Janus）之间的退化差异；(iii) 与现有 OOD 文献的位置对比。]

LOHO 是一项比留一样本严格得多的检验：留一宿主下我们扣掉了一整个化学族（每次 ~300 样本），相比之下随机划分只是抽掉每族中的少量样本。

## 5.9 不确定度量化与校准

为支撑实际的高通量筛选场景，单点预测远不够；用户需要每个预测的可信区间，以决定哪些样本值得 DFT 验证、哪些可以直接采纳。我们用 `baseline_h128_aug_long_safe` 的 4 个 seed ({42, 0, 1, 2}) 构造深度集成 (deep ensemble)，每个测试样本获得  $\hat{y} = 4 \text{ seed 平均}$ 、 $\sigma = 4 \text{ seed 标准差}$ 。脚本 scripts/uq\_calibration.py。

点估计：4-seed 深度集成 Test MAE = **0.464 eV** (vs 单 seed best 0.516 eV, **-10.1%** 精度提升)，证实集成对 IMP2D 上单 seed 噪声显著有效。我们进一步把 4 个 50-epoch + 2 个 100-epoch 的种子合并成 **6-member ensemble**，得到 **MAE 0.443 eV**，再下降 **-4.5%**——这表明跨训练长度的“快照集成 (snapshot ensemble)”思想对该任务也是有效的。

集成规模消融：在所有 6 个种子上做  $C(6, k)$  的子集选取 ( $k \in \{1, \dots, 6\}$ ,  $k = 3, 4, 5$  时随机抽 30 个组合以控制计算量)，得到 MAE 随 ensemble size 的 **efficient frontier**:

| k | MAE (mean $\pm$ std) | RMSE  | cov90 ( $\tau$ -scaled) | 备注      |
|---|----------------------|-------|-------------------------|---------|
| 1 | 0.521 $\pm$ 0.025    | 1.164 | n/a                     | 单 seed  |
| 2 | 0.477 $\pm$ 0.014    | 1.123 | 97.4%                   |         |
| 3 | 0.460 $\pm$ 0.009    | 1.109 | 95.6%                   | 性价比最佳   |
| 4 | 0.452 $\pm$ 0.006    | 1.102 | 93.8%                   |         |
| 5 | 0.446 $\pm$ 0.004    | 1.097 | 92.8%                   |         |
| 6 | 0.443 (单组合)          | 1.094 | 92.3%                   | 全部 6 种子 |

可读出三个有用规律：(i) 大部分增益在  $k = 3$  时获得 (vs 单 seed 减少 0.060 eV 中的  $\approx 0.045$ )；(ii)  $k \geq 4$  的边际收益迅速衰减 (从 0.452 到 0.443 仅 -0.009 eV)；(iii) 校准误差随  $k$  单调改善 ( $k=2$  时 cov90 略高估,  $k=4$  时 基本对齐 90%)。实际部署的最优配置是 **4-seed**，进一步加 seed 收益有限 但成本线性增长。

图 paper/figures/fig\_ensemble\_size\_ablation.png 给出 MAE / cov90 / NLL 三条曲线对  $k$  的函数关系。

主动学习模拟：把 6-成员集成  $\sigma$  用作 oracle 排序信号 (scripts/active\_learning\_demo.py)，分析在 DFT 预算约束下的工程价值：

- $\sigma$  排序前 **10%** (最可信) 样本 **MAE = 0.101 eV**,  $\sigma$  排序后 10% (最不可信) 样本 MAE = 1.809 eV, 随机 10% 样本 MAE = 0.470 eV。
- $\sigma$  选取的可信子集 vs 随机子集 **MAE 比 = 4.6 $\times$** —— $\sigma$  信号可让用户对“高置信”输出有 **5 倍** 的信任度。
- 主动学习效率：只把  $\sigma$  最高的 **15.9%** 样本送 DFT 复算就能“修复”整个测试集 50% 的绝对误差；送 48.9% 样本则修复 80% 误差。这意味着 在 IMP2D 高通量筛选场景下，用 **1/6 的 DFT 预算**即可让模型预测达到 **接近 DFT 精度**的对外输出。

图 paper/figures/fig\_active\_learning.png: (a) 不同子集大小下  $\sigma$ -排序 最可信 / 最不可信 / 随机三条曲线的 MAE 对比；(b) 累计 |error| 占比 vs “送 DFT 比例”的曲线，用以读出“50% / 80% 误差捕获”对应的 DFT 预算。

深度集成 vs **MC-Dropout**：作为单模型 UQ 的代表，我们也在同一 checkpoint 上运行 K=30 次随机 dropout 前推 (scripts/mc\_dropout\_uq.py)：

| 方法                | MAE (eV)     | mean $\sigma$ | 原始 NLL | 原始 cov90 | $\tau$       | $\tau$ 后 cov90 |
|-------------------|--------------|---------------|--------|----------|--------------|----------------|
| MC-Dropout (K=30) | 0.516        | 0.099         | 76.07  | 30.3%    | <b>10.72</b> | 94.6%          |
| 4-seed ensemble   | 0.464        | 0.329         | 2.86   | 72.5%    | 2.60         | 93.4%          |
| 6-mixed ensemble  | <b>0.443</b> | 0.331         | 1.35   | 78.9%    | 1.83         | 92.3%          |

MC-Dropout 的两个明显缺陷：(i) 不带来点估计增益——MC 平均仍是单 checkpoint 的输出 (与 0.516 等同)，相比之下深度集成把 MAE 直接降到 0.443；(ii)  $\sigma$  大幅欠估：模型的 dropout=0.1 太低导致  $\sigma$  远小于真实误差，原始 cov90 仅 30.3%，需要  $\tau \approx 11$  才能重缩放到  $\sim 95\%$  覆盖。结论：在该任务上 **深度集成全面占优**，MC-Dropout 仅在不能多次训练的极端预算下值得一用。图 paper/figures/fig\_uq\_method\_compare.png。

表 4：原始集成 vs 温度缩放校准 (详细每个指标定义见附录)

| 指标                 | 原始集成  | 温度缩放 ( $\tau=2.60$ ) | 理想         |
|--------------------|-------|----------------------|------------|
| Mean $\sigma$ (eV) | 0.329 | 0.874                | 与  err  一致 |
| NLL $\downarrow$   | 2.86  | <b>1.01</b>          | 越小越好       |

| 指标                                  | 原始集成  | 温度缩放 ( $\tau=2.60$ ) | 理想   |
|-------------------------------------|-------|----------------------|------|
| CRPS ↓ (eV)                         | 0.368 | 0.410                | 越小越好 |
| ECE in z-space ↓                    | 0.064 | <b>0.048</b>         | 0    |
| Pearson $r(\sigma,  \text{err} )$ ↑ | 0.484 | 0.364                | 1    |
| Coverage @ 50% nominal              | 39.5% | <b>75.2%</b>         | 50%  |
| Coverage @ 68% nominal              | 54.0% | <b>85.4%</b>         | 68%  |
| Coverage @ 90% nominal              | 72.5% | <b>93.4%</b>         | 90%  |
| Coverage @ 95% nominal              | 77.7% | <b>94.6%</b>         | 95%  |

结论:

1. 深度集成本身把点估计 **MAE 从 0.516 → 0.464 eV (−10%)** ——直接“白送”的免训练精度提升。
2. 原始  $\sigma$  是显著欠估的: 90% 名义置信度下经验覆盖率仅 72.5%，对应模型 过度自信。Pearson( $\sigma, |\text{err}|$ ) = 0.484 表明  $\sigma$  与误差大小之间确有正相关 但绝对量级不准。
3. 单标量温度缩放完全修复欠估: 拟合在 50% 留出半 (最大化 NLL),  $\tau = 2.595$ ; 在另一半上评估时 NLL 由 2.86 降至 1.01, 90% 名义置信度 覆盖率回升到 93.4% (几乎正好对齐)。这意味着深度集成的  $\sigma$  在 除以 / 乘以 一个标量之后即可作为可信区间使用 ——非常实用。
4.  $\sigma$  排序信息可用于 **active learning**: 把测试集按  $\tau$ -缩放后的  $\sigma$  分十 等份, 从最低十分位 (mean  $\sigma \approx 0.18$  eV, mean  $|\text{err}| \approx 0.18$  eV) 到最高 十分位 (mean  $\sigma \approx 1.37$  eV, mean  $|\text{err}| \approx 1.88$  eV), 单调上升。在实际 筛选中可以直接用  $\sigma$  设置阈值, 触发 **DFT 复算**。

图 paper/figures/fig\_uq\_calibration.png 给出 4 面板: (a)  $\sigma$  与  $|\text{err}|$  散点; (b) z-space 校准曲线; (c) 区间覆盖直方图; (d) 十分位 reliability。

### 5.10 物理可解释性: 自注意力 + occlusion 归因

模型为何能”远超经典 GNN 的截断半径”地捕捉缺陷影响? 我们用两条独立但 互相印证的诊断回答这个问题。

(a) 自注意力可视化: 从 baseline\_h128\_aug\_long\_safe 的 2 层 GeometricTransformerBlock 中按层、按 head 提取 post-softmax 注意力 权重 (脚本 scripts/attention\_baseline.py), 在 200 个测试样本上做 聚合统计。

- 平均指向缺陷原子的入向注意力 = **0.522**, 指向随机非缺陷原子 = **0.016**; 比值 **32.2×**——模型自发地把缺陷原子学成了一个”全局枢纽”, 无需 任何显式的虚拟锚点设计 (这正是原 DAST 设计的初衷, 但实证显示该 显式设计反而起反作用, 因为模型自己就会做)。
- 每 head 平均 entropy 显示明确的局部 / 全局分工: 层 2 的 head 1 / 3 entropy  $\approx 0.20$  nats (高度集中的局部模式), 而 head 2 / 4 entropy  $\approx 2.5$  nats (接近最大可能 4.7 nats 的一半, 即近似全局均匀)。这种 自然涌现的”局部 head + 全局 head”组合解释了模型为何同时具备短程 化学敏感性 + 长程缺陷敏感性。
- 层间组合诊断 (scripts/attention\_layer\_compare.py, 200-sample 聚合): 我们逐 head 逐 layer 计算”指向缺陷的入向注意力”与”head entropy”两个 量, 发现一个有趣的两阶段结构:

| layer | head | entropy (nats) | inc-attn-to-defect | 解读         |
|-------|------|----------------|--------------------|------------|
| 1     | 1    | 0.10           | <b>0.960</b>       | 极度集中: 信息汇聚 |
| 1     | 2    | 0.10           | <b>0.964</b>       | 同上         |
| 1     | 3    | 0.33           | 0.806              | 中度集中       |
| 1     | 4    | 0.96           | 0.606              | 较弥散, 仍偏向缺陷 |
| 2     | 1    | 0.17           | <b>0.934</b>       | 二次确认       |
| 2     | 2    | <b>2.10</b>    | 0.202              | 弥散: 上下文    |
| 2     | 3    | 0.22           | <b>0.917</b>       | 二次确认       |
| 2     | 4    | <b>2.82</b>    | 0.036              | 强弥散: 长程    |

即: (i) **layer 1** 所有 head 一致性地缺陷学成枢纽——这是”特征汇聚”阶段; (ii) **layer 2** 的 4 个 head 出现分化: head 1 / 3 继续以 0.92-0.93 权重指向缺陷 (”精炼”该枢纽), head 2 / 4 则放弃缺陷指向、转向接近 uniform 的全局模式 (”残余 / 上下文”)。

这种两阶段、分化式注意力与 §5.10 (b) 的 occlusion 结论”缺陷占 90.7% 的归因 + 残余 10% 扩散到 9 Å”完美对应: focused heads 提供 90% 的预测信号, diffuse heads 捕捉 9 Å 的远场修正。

图 paper/figures/fig\_attention\_layer\_compare.png 展示某 49 原子样本在 2 层 × 4 head 共 8 张子图中的 attention 热图。

- **OOD 一致性 (scripts/loho\_interp\_check.py, 80 个 LOHO MoS2 OOD 样本):** 我们用 §5.8 中的 loho\_MoS2 checkpoint (训练时完全没有见过任何 MoS2 样本) 对 80 个 MoS2 测试样本重做注意力 + occlusion 分析。结果与域内模型几乎一致:

| 量                         | 域内模型    | LOHO MoS2 模型 | 备注     |
|---------------------------|---------|--------------|--------|
| mean attn → defect        | 0.522   | 0.611        | 比域内更集中 |
| mean attn → random other  | 0.016   | 0.011        | 几乎相同   |
| attn 比例                   | 32×     | 53×          | 比域内更高  |
| defect 占总归因               | 90.7%   | 90.3%        | 完全一致   |
| mean $ \Delta $ at defect | 6.87 eV | 6.13 eV      | 数量级一致  |

这证明“模型学到的”缺陷-为-全局-枢纽”归纳偏置不是训练分布特异的——即使模型从未见过 MoS2 化学, 它仍以同样的”枢纽方式”对 MoS2 样本做推理。这是一项对该解释性发现稳健性的强证明, 把 §5.10 (a, b) 的发现从”in-distribution 现象”提升为”模型架构的一般归纳偏置”。

图 paper/figures/fig\_attention\_heads.png 与 fig\_attention\_defect\_centric.png 直观呈现该现象。

**(b) Occlusion 归因:** 对每个测试样本的每个原子  $i$ , 把  $i$  从模型的 atom\_mask 中关闭再前推, 得到  $\Delta_i = \hat{E}_f^{\text{full}} - \hat{E}_f^{\text{mask } i}$ , 作为该原子对预测形成能的”贡献”(脚本 scripts/occlusion\_attribution.py)。在 100 个测试样本上聚合:

- $|\Delta|$  在缺陷原子上 = **6.87 eV**, 在非缺陷原子上 = 0.015 eV, 比值 **448×**。
- 缺陷原子单原子贡献占总归因质量的  **$90.7 \pm 13.0\%$** ——模型的预测绝大部分由缺陷原子本身决定, 与化学直觉 (杂质原子是缺陷态的化学源头) 完全吻合。
- $|\Delta_i|$  与  $1/d_i$  (到缺陷的距离) 的 Pearson 相关达  **$0.99 \pm 0.06$** ——几乎完美的反距离衰减, 对应经典屏蔽 Coulomb 行为。
- 剔除缺陷原子后, 剩余  $|\Delta|$  总质量的 80% 分布在距缺陷  **$9.0 \pm 2.6$  Å** 以内——超过 SchNet 局部截断半径 (5 Å), 直接证明全局 Transformer 层正在捕捉真实存在的长程耦合。

把 (a) 和 (b) 放在一起: 模型既”以缺陷原子为枢纽”集中注意力 (占 90% 的预测信号), 又通过其余原子的远场 (5–10 Å) 做 ~10% 的修正, 其分配恰好匹配物理直觉。这一图景同时解释了:

- **DAST 失败的原因:** 显式虚拟锚点试图复刻”以缺陷为枢纽”的机制, 但模型已经免费学会了, 外加锚点引入额外噪声而损害精度。
- **去掉全局 Transformer 后退化到 1.40 eV 的原因** (§5.2 ablate\_local\_only): 局部消息传递无法看到 5 Å 以外的 ~10% 修正信号。
- **架构选择论据:** 纯 GNN (CGCNN, ALIGNN) + 纯局部信息会损失这长程修正; 纯全局 Transformer 又失去了缺陷邻域的精微化学。局部 + 全局混合架构是物理上最合适的归纳偏置。

图 paper/figures/fig\_occlusion\_localisation.png 给出某 49 原子超胞中  $\Delta_i$  的二维空间分布与按距离的衰减图。paper/figures/fig\_interp\_panel.png 进一步展示在 3 个对比鲜明的样本 (间隙 + 大体系 / 吸附 + TMD / 吸附 + MXene 类) 上, 缺陷-枢纽现象保持高度一致: 缺陷归因占总归因的比例介于 92.3% 至 98.2% 之间。

**(c) 特征重要性 (permutation):** 把 9 维元素特征逐列在  $Z=1..100$  间打乱, 重新评估 1065 测试样本 (5 重复)。ΔMAE 排序如下:

| 维度                | ΔMAE (eV)     | 物理含义         |
|-------------------|---------------|--------------|
| group             | <b>+1.148</b> | 元素族号 / 价电子构型 |
| valence_electrons | +0.634        | 价电子数         |
| electronegativity | +0.402        | Pauling 电负性  |
| atomic_mass       | +0.374        | 原子量          |
| period            | +0.357        | 周期数          |
| covalent_radius   | +0.314        | 共价半径         |
| ionisation_energy | +0.138        | 第一电离能        |

| 维度                | $\Delta$ MAE (eV) | 物理含义  |
|-------------------|-------------------|-------|
| vdW_radius        | +0.079            | 范德华半径 |
| electron_affinity | +0.019            | 电子亲和能 |

模型的化学先验集中于 (**group, valence\_electrons, electronegativity**)——这三者本质上都是“周期表中元素位置 + 化学键合倾向”的不同侧面，且它们彼此显著相关 (pgroup 在表中线性独立但在元素行内决定 valence\_electrons)。最末三项 (IE / vdW / EA) 对预测影响微乎其微，可作为模型简化的依据：未来版本可剔除这三个维度（缩减输入 **33%**）几乎不损精度。

图 paper/figures/fig\_feature\_importance.png 给出所有 9 维的横向条形图。

## 6. 讨论

### 6.1 为什么 DAST 在 IMP2D 上失败？

我们提出三种可能解释（按可能性排序）：

1. **任务规模偏小**：IMP2D 仅  $\sim 10^4$  样本，supercell 通常 28–49 原子。这种规模下“显式编码周期性”等结构创新的边际收益小于其引入的额外学习难度。Matformer / Crystalformer 等论文报告的强增益主要在百万级体相晶体数据上观察到。
2. **缺陷标记的不完美**：我们用启发式规则把“最后一个匹配 dopant 元素的原子”标为缺陷，但 IMP2D 也包含自代替样本 (host == dopant)，此时该规则只能任选一个。虚拟锚点把这种含噪缺陷信号集中起来，反而放大了误差。
3. **稀疏 mask 切除了远场信息**：尽管“长程效应”是物理直觉的核心动机，实际形成能很大程度上由缺陷局域化学环境决定（短程成键 / 配位变化），远场弛豫的贡献相对较弱。把所有  $r > r_{\text{global}}$  的原子裁掉反而让模型失去对超胞整体应变的感知。

### 6.2 数据增强为什么仍然有效，但远不如泄漏数字看起来那样神奇？

**真实增益 (leak-free)**：基线 0.86  $\rightarrow$  +aug 0.67  $\rightarrow$  +aug+long 0.63  $\rightarrow$  +aug+long+h128 0.52，累计 **0.34 eV / 40%** 降幅。

**虚高增益 (leaky)**：基线 0.86  $\rightarrow$  +aug+long+h128 0.21，**0.65 eV / 76%** 降幅——多出来的 0.31 eV 完全是泄漏。

旋转增强强迫模型学习“与取向无关”的几何关系；在我们使用的特征中，本来就只输入距离与角度（标量不变量），所以模型本身具备一定的旋转不变性偏置。增强的真实作用是：(i) 训练数据的取向覆盖更均匀；(ii) 高斯微扰让模型在 DFT 弛豫坐标的“邻域”上做平滑回归，而非死记 DFT 精确坐标。两者结合提供“几何归纳偏置”。

### 6.3 为什么我们的最强结果与 ALIGNN 相当但未明显超越？

ALIGNN 的核心创新——**线图机制**（节点 = 原子图的边，自然编码三体角度与配位）——在物理上是一个非常聪明的归纳偏置，与我们采用的“原子图 + RBF 角度通道”在表达能力上是等价的。我们的优势在于：(a) 更紧凑 (0.75 M vs 4 M)；(b) 训练快约  $5\times$  (5090 上单次 50-epoch 仅 12 分钟，ALIGNN 则需数小时)；(c) 数据增强提供约 0.34 eV 的可叠加收益。劣势是缺少 ALIGNN 那种“线图”对三体的精细建模，因此在精度上只能追平、未能显著超越。

### 6.4 为什么放大模型在短训练下劣化？

我们的长训练对照 (§5.1 第二张表) 给出了直接答案：在 30-epoch 设定下，hidden=128 / 4+3 层 / 8 头的 1.06 M 参数模型 Test MAE 仅 1.82 eV，劣于 0.20 M 基线的 0.86 eV；但当我们把同样 0.75 M 参数 (hidden=128 / 3+2 层 / 4 头) 的版本训练 60 epoch、配 lr=3e-4 + dropout=0.1 + weight\_decay=1e-4 后，Test MAE 降到 0.62 (无增强) / 0.52 (带 leak-free 增强)。这说明问题不在容量本身，而在于：(i) 大模型对学习率与正则化更敏感；(ii) 30 epoch 远不足以让大模型收敛。**配方层面的不匹配比模型容量本身更致命。**

## 7. 局限与未来工作

1. **跨数据集验证**：把同一 DAST 实现搬到更大的体相数据集 (Materials Project) 跑一次，看看负面结果是否还成立。如成立，则说明 DAST 思路本身有问题；如不成立，则确认 IMP2D 的特殊性。
2. **更强的物理增强**：除了旋转 + 微扰，还可加入“超胞复制  $\rightarrow$  形成能按原子数缩放”等增强；以及“Wyckoff position 替换”等晶体学增强。增强数量也可继续放宽到  $5\times / 10\times$  (受存储与训练时间约束)。
3. **不确定度量化升级**：本文 §5.9 已给出 deep ensemble + 温度缩放校准；后续可比较 EDL (evidential deep learning)、SWAG、Laplace approx 等“单模型”版本在精度 / 校准 / 计算开销三角上的 trade-off。

4. 基于  $\sigma$  的主动学习闭环：把 §5.9 给出的可信区间接到 DFT 验证管线：把  $\sigma$  高于阈值（例如 NLL 排序前 5%）的样本送入 DFT，再迭代训练。预期可在  $\sim 10\times$  DFT 预算节省下达到与全标注相当的精度。
5. 多 host 联合 LOHO + 元学习：§5.8 的单 host 留一是基础；进一步可做 leave-K-host-out 或元学习训练（例如 MAML），让模型对“快速适应未见 化学族”具备先验。
6. 可解释性向材料筛选反馈：§5.10 显示模型把缺陷学成枢纽，但残余 10% 信号扩散到 9 Å 内。后续可量化”剩余 10% 中哪些近邻原子贡献最大”，形成”近邻-缺陷耦合度”特征，反向指导 DFT 计算的 supercell 大小选择。
7. 重新跑 ALIGNN 自己：本文 ALIGNN 数字直接引用团队前期复现，可能存在实现差异。理想情况下应该用同一份 cleaned 划分把 ALIGNN 自己跑一次（含 leak-free aug 版本）以彻底排除任何疑虑。

## 8. 结论

我们对二维材料缺陷形成能预测做了系统的算法对比，得到七个关键结论：

1. 朴素 SchNet+Transformer 混合架构 + leak-free 几何不变性增强 + 适度长训练可在 IMP2D 上以 0.75 M 参数取得 Test MAE 0.516 eV，与 4 M 参数的 ALIGNN 相当，参数量约为后者 1/5；这是该任务上一个实用、可复现的紧凑基线。
2. 包括”虚拟缺陷锚点”、“晶格自连接编码”、“星型稀疏注意力”在内的 若干结构创新在该任务上均产生负贡献，提示该规模数据上的复杂注意力创新需要谨慎评估。
3. 盲目放大模型容量在短训练预算下也会劣化精度，需要配套的训练长度、学习率与正则化精调。
4. 常用的”先合并  $K\times$  aug、再随机划分”工作流会以  $\sim 99\%$  概率把 测试样本的某个增强副本塞入训练集，造成 0.31 eV 的虚假精度提升；该领域应当默认采用先划分后增强的严格做法，本文 build\_leak\_free\_aug.py 提供了即用脚本。
5. 深度集成 (4 seed) 提供  $-10\%$  免训练精度增益 + 单标量温度缩放 恢复良好校准：将 MAE 从 0.516  $\rightarrow$  0.464 eV、NLL 从 2.86  $\rightarrow$  1.01、90% 区间覆盖率从 72.5%  $\rightarrow$  93.4%。这意味着模型可以输出可直接采纳的 置信区间——这是二维材料高通量筛选闭环里的核心需求。
6. 留一宿主验证 (LOHO) 给出更严格的 OOD 评估：5 个二维材料家族的 留一退化倍数（详见 §5.8）告诉我们模型在”训练时从未见过的化学族”上的泛化界限，应作为该领域基准的标配指标。
7. 物理可解释性双诊断揭示了架构的归纳偏置匹配：通过自注意力可视化与 occlusion 归因，证实模型自发地把缺陷原子学成了全局枢纽 (attention  $32\times$ 、attribution  $448\times$ 、单原子贡献 90.7%)，这正是 原 DAST 显式锚点试图复刻的；同时缺陷外的  $\sim 10\%$  残余信号扩散到 9 Å 半径，超过 SchNet 5 Å 截断，直接为”局部 + 全局混合架构”提供物理 依据。

这些发现为后续设计”可解释、可扩展、面向缺陷工程”的二维材料高通量预测 平台提供了五条务实指引：(i) 先做几何不变性增强（且必须 leak-free）；(ii) 慎重引入复杂注意力；(iii) 把模型容量与数据规模 + 训练预算匹配；(iv) 部署时使用深度集成 + 温度缩放校准的概率预测；(v) 面向新化学族 推广前先用 LOHO 评估。

## 参考文献

- [1] Wu J, *et al.* Graph transformer model integrating physical features for projected electronic density of states prediction. *J. Phys. Chem. A*, 2025, **129**(25): 5700-5708.
- [2] Yan K, *et al.* Periodic graph transformers for crystal material property prediction. *NeurIPS*, 2022, **35**: 15066-15080.
- [3] Hua H, Lin W. Local-global associative frames for symmetry-preserving crystal structure modeling. *arXiv:2505.15315*, 2025.
- [4] Yan K, *et al.* Invariant tokenization of crystalline materials for language model enabled generation. *NeurIPS*, 2024, **37**: 125050-125072.
- [5] Kazeev N, *et al.* Wyckoff transformer: Generation of symmetric crystals. *arXiv:2503.02407*, 2025.
- [6] Lin Y, *et al.* Efficient approximations of complete interatomic potentials for crystal property prediction. *ICML*, 2023: 21260-21287.
- [7] Taniai T, *et al.* Crystalformer: Infinitely connected attention for periodic structure encoding. *arXiv:2403.11686*, 2024.
- [8] Hossen M F, *et al.* Defects and defect engineering of two-dimensional transition metal dichalcogenide (2D TMDC) materials. *Nanomaterials*, 2024, **14**(5): 410.
- [9] Zhang J, *et al.* Graph neural network guided evolutionary search of grain boundaries in 2D materials. *ACS Appl. Mater. Interfaces*, 2023, **15**(16): 20520-20530.

- [10] Schleberger M, Kotakoski J. 2D material science: Defect engineering by particle irradiation. *Materials*, 2018, **11**(10): 1885.
- [11] Reiser P, *et al.* Graph neural networks for materials science and chemistry. *Communications Materials*, 2022, **3**(1): 93.
- [12] Zhang Y, *et al.* Generalizable machine learning potentials for quantum-accurate predictions of non-equilibrium behavior in 2D materials. *Comput. Methods Appl. Mech. Eng.*, 2026, **448**: 118502.
- [13] Vaswani A, *et al.* Attention is all you need. *NeurIPS*, 2017, **30**.
- [14] Schütt K T, *et al.* SchNet: A deep learning architecture for molecules and materials. *J. Chem. Phys.*, 2018, **148**(24): 241722.
- [15] Choudhary K, DeCost B. Atomistic line graph neural network for improved materials property predictions. *npj Comput. Mater.*, 2021, **7**: 185.
- [16] Xie T, Grossman J C. Crystal graph convolutional neural networks for accurate and interpretable prediction of material properties. *Phys. Rev. Lett.*, 2018, **120**: 145301.
- [17] Beltagy I, *et al.* Longformer: The long-document transformer. *arXiv:2004.05150*, 2020.
- [18] Pandey A, *et al.* Computational Materials Repository (CMR) database. <https://cmr.fysik.dtu.dk/>

## 复现指南

```
# 1. 准备代码与环境 (要求 Python 3.10, NVIDIA GPU 强烈推荐)
git clone https://github.com/chimeraHHH/2d-defect-dast.git && cd 2d-defect-dast
python3 -m venv .venv && source .venv/bin/activate
# RTX 50 系必须 cu128
pip install --index-url https://download.pytorch.org/whl/cu128 torch
pip install -r requirements.txt

# 2. 拉取 IMP2D 原始数据库
mkdir -p data/raw
curl -L https://cmr.fysik.dtu.dk/_downloads/imp2d.db -o data/raw/imp2d.db

# 3. 预处理 (约 1 min CPU)
python scripts/prepare_dataset.py

# 4. 构建 leak-free 增强数据集 (约 4 min CPU; 输出 ~2.2 GB)
python scripts/build_leak_free_aug.py

# 5. 复现头条配置 (h128, 50 epoch, 12 min on RTX 5090)
python -m src.train --config configs/baseline_h128_aug_long_safe.yaml

# 6. 全部消融与对照
bash scripts/run_queue.sh          # 30-epoch baselines + DAST 系列
# 5-seed 多种子稳定性
for s in 0 1 2 3 42; do
    python -m src.train --config configs/baseline_h128_aug_long_safe_seed${s}.yaml
done

# 7. 汇总图表 (含 S5.7 的泄漏对照)
python scripts/analyze_results.py
python scripts/make_figures.py
python scripts/error_analysis.py baseline_h128_aug_long_safe
```

所有训练日志、checkpoint、test\_predictions.npz 全部保留在 results/<run>/ 下; results/summary.md 是自动生成的统一指标表，论文中的全部数字均可从 metrics.json 中读出，不需任何手工挑拣。