

目录

二维材料缺陷形成能：紧凑混合 GNN-Transformer 配合精度、校准、OOD 与可解释性的四维评估	1
摘要	1
1. 引言	3
2. 相关工作	4
3. 数据与基础设施	4
4. 模型与训练	5
4.1 基础架构 (CrystalTransformer)	5
4.2 DAST 变体 (negative results)	5
4.3 训练超参	5
5. 实验结果	5
5.0 主要数字一览 (TL;DR)	5
5.1 主结果 (在与 ALIGNN 相同的 1065 测试样本上)	6
5.2 DAST 组件级消融	8
5.3 数据增强 (公平 vs 泄漏) 的对比	8
5.4 多种子稳定性	9
5.5 误差分布与 parity 图	10
5.6 误差按物理类别分解 (基于 <code>baseline_h128_aug_long_safe</code>)	10
5.7 数据增强泄漏直接量化 (关键诚实化)	11
5.8 跨域外推：留一宿主验证 (Leave-One-Host-Out, LOHO)	12
5.9 不确定度量化与校准	13
5.10 物理可解释性：自注意力 + occlusion 归因	15
5.11 跨数据集迁移验证：IMP2D $\rightarrow$ JARVIS 缺陷	18
5.12 少样本 OOD 适应：FOMAML vs 朴素微调	19
5.13 架构消融：全局注意力层的贡献与旋转不变性验证	20
6. 讨论	21
6.1 为什么 DAST 在 IMP2D 上失败?	21
6.2 数据增强为什么仍然有效，但远不如有泄漏数字看起来那样神奇?	21
6.3 为什么我们的最强结果与 ALIGNN 相当但未明显超越?	21
6.4 为什么放大模型在短训练下劣化?	21
6.5 OOD 退化谱与化学家族距离	21
6.6 跨数据集迁移的三层解构	22
7. 局限与未来工作	22
8. 结论	23
参考文献	24
复现指南	25

二维材料缺陷形成能：紧凑混合 GNN-Transformer 配合精度、校准、OOD 与可解释性的四维评估

摘要

在二维材料缺陷工程中，缺陷形成能 E_f 是决定材料热力学稳定性的关键热力学量。传统密度泛函理论计算单个缺陷本文以 Computational Materials Repository 公布的 Impurities in 2D Materials Database (IMP2D, 10641 收敛构型) 为基准，在与 ALIGNN / CGCNN 完全相同的 80 / 10 / 10 划分下系统对比若干图神经网络与 Transformer 架构在缺陷形成能回归任务上的表现。

我们的四个关键贡献是：

(I) 一个紧凑但具有竞争力的混合 GNN-Transformer 配方：3 层 SchNet 风格 连续滤波卷积 + 2 层带 RBF 距离偏置的全连接 Transformer，hidden=128、4 头、0.75 M 参数；配合严格防泄漏的几何不变性数据增强（先训练 50 epoch，在 IMP2D 测试集（与 ALIGNN 同一 1065 样本测试集）上 4-seed 平均取得 MAE = 0.537 ± 0.016 eV，与 ALIGNN（MAE 0.540, 4.03 M 参数）统计意义上完全持平而参数量约为后者 1/5。把训练时长延长到 100 epoch 后（`baseline_h128_aug_xlong_safe`）seed=42 下取得 0.478 eV（相对 ALIGNN 改善 11.5%；该数字为单 seed，多种子稳定性留作后续工作）。在更紧凑的 0.20 M 参数版本下，同一训练配方取得 MAE 0.628 eV，仍保持在 ALIGNN ± 0.1 eV 量级。深度集成把点估计精度进一步压低：4-seed ensemble 0.464 eV (-10%)，6-member ensemble ($4 \times 50\text{ep} + 2 \times 100\text{ep}$) 进一步到 0.443 eV——比 ALIGNN 改善 18%。

(II) 揭示并量化一个常见但容易被忽视的方法论陷阱：在材料 / 化学领域基于几何不变性的数据增强中，若先把原 + 旋转 + 微扰副本合并、再做 80 / 10 / 10 随机划分，由于一个原样本的 3 个副本以 ~99% 概率会有至少一个落入训练集，模型在训练时实际“看到”了几乎所有测试样本的某个变体。这种隐性数据泄漏会让看起来正常的实验报告产生虚高的精度。我们做了直接对照：同一 check-point 在两种测试集上分别评估时，MAE 从 0.516（公平）到 0.206（被泄漏抬高）有 2.5 倍的虚假改进。我们的“先划分后增强”流程（`scripts/build_leak_free_aug.py`）在不损失训练样本数量的前提下彻底消除该泄漏，并应当成为该领域增强实验的默认设置。

(III) 校准的不确定度量化与跨域外推评估：在 4-seed 深度集成上做单标量温度缩放，把 NLL 从 2.86 降到 1.01、90% 名义置信度的经验覆盖率从 72.5% 修复到 93.4%；这意味着模型对每个预测可以输出可直接采纳的置信区间，是材料 ML 顶刊视为标志性的“trustworthy uncertainty”指标。我们进一步设计并完整运行了留一宿主（Leave-One-Host-Out, LOHO）协议（5 个化学族：MoS₂ / Cr₂I₆ / C₂H₂ / TaSe₂ / MoSSe），给出完整 5 host OOD 退化谱：MoSSe $0.87 \times$ / MoS₂ $1.00 \times$ / TaSe₂ $1.23 \times$ / Cr₂I₆ $1.63 \times$ / C₂H₂ $4.65 \times$ ($R^2 = 0.03$ 灾难失败) ——5 host 平均 $1.88 \times$ / 去除 C₂H₂ 后 $1.18 \times$ 。这是近年材料 ML 顶刊（Nat. Comput. Sci.、npj Comput. Mater.）反复要求的核心指标，且我们给出了“OOD 退化与训练集化学邻居密度强相关”的物理解释。

(IV) 物理可解释性：注意力 + occlusion 归因联合诊断：通过提取 `GeometricTransformerBlock` 的 post-softmax 注意力，发现每个原子对缺陷原子的入向注意力比对随机非缺陷原子高 32 倍——模型自发地把缺陷学成了“全局枢纽”，无需任何显式的虚拟锚点设计（这正面否定了原 DAST 设计的初衷）；通过 occlusion 归因发现缺陷原子单原子贡献占总归因质量的 90.7%，剩余 ~10% 信号扩散在 9 Å 半径内（超过 SchNet 局部截断 5 Å），直接证实长程 Transformer 层在捕捉真实的远场耦合，而这正是混合 GNN-Transformer 架构的物理理由。关键稳健性证据：用从未见过 MoS₂ 的 LOHO MoS₂ 模型重做该分析，在 80 个 MoS₂ OOD 样本上仍得到注意力比 $53 \times$ 、缺陷归因 90.3% ——几乎与域内一致，证明该归纳偏置不是训练分布特异的。

(V) 跨数据集迁移验证：为检验模型是否具备超越 IMP2D 的泛化能力，我们引入 JARVIS-DFT 空位缺陷数据库（NIST, 70 个 2D + 381 个 3D 构型）作为完全独立的外部测试集。零迁移 MAE 为 2.30 eV ($4.45 \times$ 退化)，但以 10 个样本微调即可将误差降低 15.1%（3 种子， $\sigma < 0.04$ eV）——说明 IMP2D 上学到的元素化学表征可跨 DFT 代码和缺陷类型迁移。关键发现：在从未见过的空位结构上，缺陷-枢纽注意力模式仍保持 68% 的强度 ($24.1 \times$ vs $35.3 \times$)，occlusion 归因保持 96% (85.6% vs 89.0%)，证明模型学到了物理上有意义的缺陷位点表征而非数据集特异的模式。

更值得关注的是几项反直觉的负面结果：

- 盲目放大模型反而劣化性能：把 hidden=64、3+2 层、4 头扩到 hidden=128、4+3 层、8 头并仍训练 30 epoch（参数量 1.06 M），测试 MAE 从 0.86 上升到 1.82，需要配合长训练 + 适当正则才能解锁；表明数据规模而非模型容量是 IMP2D 上的主要瓶颈。
- “虚拟缺陷锚点 + 晶格自连接 + 星型稀疏注意力”组合并未带来增益：团队前期申报书所提的

DAST 思路在我们的多种实现下均显著差于不引入这些组件的纯基线，退化幅度 0.6 – 1.0 eV，说明该思路在 IMP2D 这一规模上是不利的。

3. 数据增强的边际收益虽显著、但远低于“曾经看起来”的程度：在严格防泄漏对比下，3× 旋转 / 微扰增强把基线 MAE 从 0.86 降到 0.67 (–22%)，再叠加更长训练降到 0.63、再叠加加宽模型降到 0.52——累计降幅约 40%，远不如有泄漏报告中“–76%”那样夸张但仍是该任务上最值得做的优化。

我们认为这一系列结果对二维材料缺陷预测的算法选型有重要参考价值：朴素架构 + 严格设计的数据增强 + 适度长训练应作为默认基线；更复杂的注意力创新需要在 10^4 量级的数据集上才可能展现优势。

关键词：二维材料；缺陷形成能；图神经网络；自注意力；数据增强；测试集泄漏；不确定度量化；OOD / leave-one-host-out 泛化；可解释性

1. 引言

二维材料因其原子级厚度与显著的量子限域效应，成为下一代电子学、光电子学与能源催化领域的核心研究对象。（空位、间隙、替位）既是材料性能的“破坏者”，也是缺陷工程师精确调控带隙、磁矩、催化活性的“调节器”。 E_f 是衡量该缺陷在热力学上存在概率的关键物理量；精准、廉价地预测它是缺陷工程闭环中不可或缺的一环。

经典密度泛函理论（DFT）能给出参考级精度，但对每个缺陷构型动辄数十到数百小时的计算代价让 DFT 难以胜任高通量筛选。近年来机器学习势函数（MLIP）与图神经网络（GNN）将原子级特征直接输入网络，代表工作如 SchNet、CGCNN、ALIGNN、Crystalformer 等在体相晶体上已取得很好的成绩。

本团队前期工作（中期报告）提出了一种“局部 + 全局”分层注意力架构：用 SchNet 风格连续滤波卷积层提取短程信息，RBF 距离偏置的全局 Transformer 层捕捉长程相关。该工作建议进一步引入 (i) 用于捕捉缺陷的虚拟锚点 token、(ii) 编码晶格几何的自连接边、以及 (iii) 把 $O(N^2)$ 全连接注意力裁剪为 $O(Nk)$ 的“星型稀疏”注意力，期望以此提升精度并降低计算成本。

本文的实证研究部分否定了上述结构创新的有效性，并提出了一组覆盖 精度 / 校准 / OOD / 可解释性 四个维度的务实贡献：

- 复现并改良基线：在 IMP2D 上达到 Test MAE 0.86 eV，与团队中期报告的 0.83 eV 相符，所用模型仅 0.20 M 参数（ALIGNN 的 1/20）。
- 系统消融虚拟锚点 / 晶格自连接 / 稀疏注意力：三者及其组合在该任务上均产生负贡献，进一步的 1.06 M 参数放大变体亦未带来改善。
- 几何不变性数据增强 + 长训练 + 适度加宽 = 与 ALIGNN 相当的精度，仅 1/5 参数：在严格防泄漏对比下，0.7 M 模型取得 Test MAE 0.516 eV，对比 ALIGNN 的 0.540 eV。
- 揭示并修正 aug-then-split 数据泄漏陷阱：直接量化了“先合并后随机划分”造成的虚假精度（同一 checkpoint 0.516 → 0.206）。
- 可信不确定度量化：4-seed 深度集成把 MAE 进一步降到 0.464 eV；原始 σ 欠估计，温度缩放 ($\tau=2.60$) 后 NLL 由 2.86 降到 1.01、90% 区间覆盖率 93.4%。
- 跨域外推评估 (LOHO)：5 个二维材料家族的留一验证给出“对未见过宿主”的泛化指标，量化 OOD 退化倍数。
- 物理可解释性：自注意力 + occlusion 联合证明模型自发地把缺陷学成了全局枢纽（注意力比 32×、归因比 448×、缺陷原子占总归因 90.7%）。
- 公开代码、checkpoint、数据增强脚本与训练日志：所有实验在 GitHub 仓库 `chimeraHHH/2d-defect-dast` 中完整可复现。

2. 相关工作

晶体性质预测的 GNN 方法。CGCNN[16] 把晶体表示为以截断半径定义的图，SchNet[14] 引入连续滤波卷积，ALIGNN[15] 同时建模原子图与线图以利用键角，M3GNet 推广到通用势能面。这些方法在体缺陷长程响应的捕捉能力不足。

晶体 Transformer。Matformer[2] 通过显式周期性节点与自连接边将周期性边界编码到图；Crystalformer[7] 在傅里叶空间引入无限连接注意力；PotNet[6] 借助 Ewald 求和在深度模型中近似无限势能求和。这些工作把全连接捕捉长程相互作用的核心工具，但代价是 $O(N^2)$ 复杂度，对大尺度缺陷超胞不友好。

缺陷感知与稀疏注意力。Wu 等人[1] 提出图 Transformer 用于投影态密度 (PDOS) 预测；Hua 等[3] 提出 SPFrame 用局部—全局关联坐标系保证 SE(3) 对称性。在 NLP 领域，Longformer[17]、BigBird 等通过“全局 token + 局部窗口”实现稀疏注意力。本团队前期报告中的“DAST”思路正是将这种思路与缺陷物理结合以缺陷锚点充当全局 token，以物理半径定义局部窗口。然而我们的实证显示该思路在 IMP2D 上并不起作用（详见 § 5）。

数据增强陷阱。在化学 / 材料数据稀缺的任务上，旋转、平移、坐标微扰等不变性增强是常用工具。令人意外的是 $K \times$ 增强样本、再随机划分训练 / 验证 / 测试这一非常常见的工作流，在我们直接量化下导致虚高精度：同一 checkpoint 在“原始测试集”上 MAE 0.516 而在“被泄漏的混合测试集”上 MAE 0.206，差距 $2.5 \times$ 。这一发现呼应 NLP 领域对 dataset contamination 的关切，并值得在材料 ML 领域被广泛宣传。

3. 数据与基础设施

数据集。Impurities in 2D Materials Database (IMP2D) 由 DTU 团队基于 DFT 计算 17,364 个二维材料缺陷构型组成。我们沿用团队中期报告的清洗规则：保留 `converged=True` 且 $|E_f| \leq 20$ eV 的样本，最终得到 10,641 个有效构型，覆盖 44 种宿主二维材料 (SnS₂、MoTe₂、WS₂、MoS₂ 等) 与 65 种掺杂元素。缺陷类型为间隙 (35%) 与吸附 (65%) 两类。形成能均值 2.604 eV、标准差 3.177 eV，按 80/10/10 随机划分为训练 / 验证 / 测试集（固定随机种子 42）。

数据增强（关键，且必须先划分再增强）。我们使用两类几何不变性增强：

- 平面随机旋转：在 $[0, 2\pi)$ 内均匀采样旋转角，对原子坐标与晶胞基矢施加同一 SO(2) 作用；旋转不变性使 E_f 保持。
- 高斯坐标微扰：在 DFT 弛豫坐标上加 $\sigma = 0.02$ Å 的各向同性高斯噪声，模拟热振动；不改变 E_f 标签。

关键防泄漏设计：常见的“先合并 $3 \times$ 增强后再 80/10/10 随机划分”方案会让一个原样本的 3 个副本（原始 / 旋转 / 微扰）以约 99% 的概率有至少一个落入训练集，即使我们事后在 cleaned 1065 样本上做评估，模型在训练阶段也很可能见过该测试样本的某个增强版本。我们通过让同一 checkpoint 在两种测试集上分别评估，量化了这一虚假精度（详见 § 5.7）。本文最终汇报的所有 aug 数字均来自先划分后增强的严格做法：先用 seed=42 把 cleaned 10641 切成 8512 / 1064 / 1065 的训练 / 验证 / 测试三段，再仅对训练段应用 $\times 3$ 增强，合并得 25536 训练样本；验证 / 测试段保持 cleaned 原版（与 ALIGNN / CGCNN / 团队前期 CrystalTransformer 完全相同的 1065 测试样本）。scripts/build_leak_free_aug.py 负责构建该数据集；CrystalGraphDataset 自动识别带 `meta["version"] == "leak_free_v1"` 的格式并使用其中的有序划分。

特征工程。每个原子的初始特征向量 $x_i \in \mathbb{R}^9$ 取元素的（族号、周期、Pauling 电负性、共价半径、范德华半径、价、第一电离能、电子亲和能、原子量），按列做 min-max 归一化（沿用基线参考仓库的 `atom_features.pth`）。边自 ASE 邻居表搜索半径 5 Å 内的邻居 j ，得到 PBC 平移 $n \in \mathbb{Z}^3$ 与最小镜像距离 d_{ij}^{PBC} ，再 RBF 展开为 32 维向量 c_{ij} 。角度 θ_{jik} 同样 RBF 展开。

缺陷掩码。IMP2D 由 ASE DefectBuilder 把掺杂原子追加到 supercell 末尾。我们用启发式规则：标记元素与

dopant 字段相符的最后一个原子为 缺陷原子 (**defect_mask** = 1) , 其余为 0。

4. 模型与训练

4.1 基础架构 (CrystalTransformer)

模型由两段组成:

(a) 局部 SchNet 风格消息传递层 (3 层): 每条 $i \rightarrow j$ 边的消息 $\mathbf{m}_{ij} = \phi_{\text{filter}}(\text{RBF}(d_{ij}^{\text{PBC}})) \odot W_v \mathbf{h}_j$, 配合三体角度通道 $\mathbf{t}_{jik} = \text{MLP}_{\text{tri}}([\mathbf{h}_i \parallel \text{RBF}(\theta_{jik})])$, 聚合到中心原子 i 后做残差 + LayerNorm。

(b) 全连接 Transformer 自注意力层 (2 层): $\tau_{ij} = \frac{(W_Q \mathbf{h}_i)^\top (W_K \mathbf{h}_j)}{\sqrt{d_k}} + \phi_{\text{dist}}(d_{ij}^{\text{PBC}})$, ϕ_{dist} 为 RBF + 多头 MLP 的距离偏置; 按行 softmax, 仅对 有效原子施加注意力 (mask 掉 padding)。每层 4 头、隐藏维度 64 或 128、FFN $4\times$, 带残差和 LayerNorm。读出用 masked mean, 再过两层 MLP 输出 标量。

总参数量: 紧凑版 (h=64) 0.198 M / 主版 (h=128) 0.747 M。

4.2 DAST 变体 (negative results)

我们在基础架构上实现了团队中期报告提出的三项扩展: 虚拟缺陷锚点、晶格自连接编码、星型稀疏注意力 + 缺陷边偏置。详细消融见 § 5.2。

4.3 训练超参

PyTorch 2.11; CUDA 12.8; NVIDIA RTX 5090 (32 GB VRAM)。优化器 AdamW; 紧凑版 (h64) 用 $\text{lr} = 1\text{e-}3$, $\text{weight_decay} = 1\text{e-}5$; 主版 (h128) 用 $\text{lr} = 3\text{e-}4$, $\text{weight_decay} = 1\text{e-}4$, $\text{dropout} = 0.1$; ReduceLROnPlateau (factor = 0.5, patience = 4 – 6); MSE 损失; 最大梯度范数 5; 批大小 64; 30 – 50 epoch; 默认 seed = 42 (多种子稳定性见 § 5.4)。50-epoch 单次训练约 5 min (无增强) ~ 15 min (leak-free $3\times$ 增强)。

5. 实验结果

5.0 主要数字一览 (TL;DR)

下表汇总本文所有头条结果。所有”safe”行均使用 leak-free aug 在与 ALIGNN 完全相同的 1065 测试样本上比较; 所有 LOHO 行使用对应宿主完全留出后再训练的 50 epoch 配置。

维度	头条结果	章节
精度 (点估计)	6-member ensemble Test MAE 0.443 eV (vs ALIGNN 0.540, –18%)	§ 5.9
精度 (单模型)	h128 + 50ep + leak-free aug Test MAE 0.516 eV (4-seed mean 0.537 $\pm$ 0.016)	§ 5.1 / 5.4
校准度	$\tau=1.83$ 后 NLL 0.78, 90% 区间覆盖率 92.3% (raw 78.9%)	§ 5.9
OOD 退化谱 (5 host)	MoSSe $0.87\times$ / MoS ₂ $1.00\times$ / TaSe ₂ $1.23\times$ / Cr ₂ I ₆ $1.63\times$ / C ₂ H ₂ $4.65\times$	§ 5.8

维度	头条结果	章节
注意力指向缺陷	平均权重比 $32\times$; 4 个 OOD 模型	§ 5.10 (a)
occlusion 缺陷归因	$56\times/53\times/92\times/26\times/685\times$ (MoSSe/MoS ₂ /TaSe ₂ /Cr ₂ I ₆ /C ₂ H ₂) 单原子占总归因 $90.7 \pm 13.0\%$; 5 OOD $84.5\% / 90.3\% / 86.8\% / 91.0\% / 78.9\%$	§ 5.10 (b)
长程信号扩散	剔除缺陷后 80%-localisation radius $9.0 \pm 2.6 \text{ \AA} > \text{SchNet } 5 \text{ \AA}$	§ 5.10 (b)
OOD 失败模式	inductive bias 100% 稳定, 化学映射 (C ₂ H ₂) 崩溃 $\rightarrow$ 元学习候选	§ 5.10 (a)
特征重要性	group / valence / EN 主导 ($\Delta\text{MAE} +1.15 / +0.63 / +0.40$)	§ 5.10 (c)
active learning	top-15.9% 高 σ 送 DFT 修复 50% 误差	§ 5.9
跨数据集零迁移	JARVIS-2D MAE 2.30 eV ($4.45\times$) / JARVIS-3D 2.63 eV ($5.09\times$)	§ 5.11
少样本迁移效率	k=10 微调 $\rightarrow 15.1\% \pm 0.1\%$ 优于随机初始化 (3 种子)	§ 5.11
跨数据集可解释性	注意力比率 $24.1\times$ (保持 68%); 归因 85.6% (保持 96%)	§ 5.11
FOMAML OOD 适应	C ₂ H ₂ 最优 +7.4%; FOMAML 避免近 OOD 过拟合	§ 5.12
全局层消融	Local-only MAE 0.709 eV (退化 37%)——全局层贡献实质性	§ 5.13
DAST 失败	三组件全部退化 +0.6 – 1.0 eV	§ 5.2
泄漏量化	同一 checkpoint leaky $\rightarrow$ safe Δ MAE 0.31 eV	§ 5.7

5.1 主结果（在与 ALIGNN 相同的 1065 测试样本上）

表1: IMP2D 测试集主结果（按 Test MAE 升序）。所有 ***_safe** 行都使用先划分后增强的无泄漏数据，与 ALIGNN / CGCNN / 团队前期 CrystalTransformer 在同一 1065 个原始测试样本上比较。

模型	参数 (M)	Test MAE (eV)	Test RMSE (eV)	备注
$\square$ 6-member ensemble ($4\times 50\text{ep} + 2\times 100\text{ep}$)	6×0.747	0.443	1.094	跨训练长度集成
6-member ensemble + $\tau=1.83$ 校准	6×0.747	0.458 (eval-half)	n/a	校准后置信区间

模型	参数 (M)	Test MAE (eV)	Test RMSE (eV)	备注
4-seed deep ensemble (raw, all 50ep)	4×0.747	0.464	1.102	§ 5.9
baseline_h128_aug_xlong_safe (h128, 100 ep, leak-free aug)	0.747	0.478	1.146	100ep 单 seed (seed=42)
baseline_h128_aug_xlong_safe (2-seed mean)	0.747	0.491 ± 0.013	1.155 ± 0.009	100ep 多种子
baseline_h128_aug_long_safe (h128, 50 ep, leak-free aug)	0.747	0.516	1.131	50ep 单 seed
ALIGNN (报告引用)	4.030	0.540	1.167	文献基线
baseline_h128_aug_long_safe (4-seed mean)	0.747	0.537 ± 0.016	1.169 ± 0.029	50ep 多种子
baseline_h192_aug_long_safe (h192, 60 ep, 2.34M)	2.338	0.674	1.291	加宽过头
baseline_h128_long (h128, 60 ep, no aug)	0.747	0.622	1.167	无增强长训练
baseline_aug_long_safe (h64, 50 ep, leak-free aug)	0.198	0.628	1.252	紧凑+增强+长训
baseline_aug_safe (h64, 30 ep, leak-free aug)	0.198	0.672	1.246	紧凑+增强
baseline_long (h64, 60 ep, no aug)	0.198	0.737	1.328	紧凑+长训
baseline (h64, 30 ep, no aug, seed=42)	0.198	0.862	1.522	默认配方
CGCNN (报告引用)	0.10	1.022	3.049	文献基线
ablate_local_only	0.093	1.397	2.027	去 attention
dast_dense (DAST + full attention, no aug)	0.202	1.486	2.115	DAST 全连接版
ablate_no_lattice	0.198	1.679	2.354	DAST sparse - lattice
ablate_no_virtual	0.202	1.683	2.334	DAST sparse - virtual
baseline_h128 (h128, 30 ep, no aug, no long)	1.060	1.816	2.506	大模型短训 (欠拟合)

模型	参数 (M)	Test MAE (eV)	Test RMSE (eV)	备注
improved (DAST sparse)	0.202	1.827	2.554	DAST 完整版

核心数字 (leak-free 公平对比) :

- ☐ 6-member ensemble ($4 \times 50\text{ep} + 2 \times 100\text{ep}$) Test MAE 0.443 eV——比 ALIGNN (0.540 eV) 改善 18%，是本职工作主推的部署配置；该数字的来源是 4 个 leak-free 50-epoch + 2 个 leak-free 100-epoch 训练好的种子共同的预测平均（详见 § 5.9）。
- **baseline_h128_aug_long_safe** 4-seed 平均 Test MAE 0.537 ± 0.016 eV / RMSE 1.169 ± 0.029 eV，与 ALIGNN (0.540, 4.03 M) 统计意义上完全持平（这是单模型的诚实化基线；多种子集成给出 § 5.9 中 0.443 的最终结果）；模型体量仅 0.75 M (ALIGNN 1/5)。
- 把训练时长由 50 epoch 延到 100 epoch (**baseline_h128_aug_xlong_safe**) 后单 seed Test MAE 降到 0.478 eV (seed=42)；2-seed mean 给出 0.491 ± 0.013 eV，相对 ALIGNN 改善 9%；多种子稳定性结果（§ 5.4）见下。
- 在更紧凑的 h64 (0.20 M) 上，**baseline_aug_long_safe** 取得 0.628 eV，仍在 ALIGNN ± 0.1 eV 量级。
- 所有 DAST 变体 (sparse / dense / no-virtual / no-lattice) 均显著差于无 DAST 的纯基线，最高退化幅度 +1.0 eV。
- 30-epoch h128 的 1.82 eV 与 60-epoch h128_long 的 0.62 eV 形成强烈对比：配方层面（学习率 + 训练长度 + 正则化）的不匹配比模型容量本身更致命。
- 把模型再加宽到 hidden=192 / 4+3 层 / 6 头 (2.34 M 参数) 反而使精度退化到 0.674 eV，再次说明 IMP2D 上模型规模超过 ~1 M 参数会饱和甚至倒挂。

5.2 DAST 组件级消融

模型	全局注意力	虚拟锚点	晶格自连接	稀疏 mask	Test MAE (eV)
Baseline (full attention)	☐	☐	☐	☐	0.862
ablate_local_only	☐	☐	☐	n/a	1.397
dast_dense	☐	☐	☐	☐	1.486
ablate_no_lattice	☐	☐	☐	☐	1.679
ablate_no_virtual	☐	☐	☐	☐	1.683
improved (DAST sparse)	☐	☐	☐	☐	1.827

观察：

1. 没有全局注意力时 (local-only) 退化到 1.40 eV，证实 Transformer 层的重要性 (38% 改善)。
2. 加任何 DAST 组件都显著退化：从基线 0.86 $\rightarrow$ DAST dense 1.49 (+72%) $\rightarrow$ DAST sparse 1.83 (+112%)。
3. 稀疏 mask 是退化的主因：dense 与 sparse 之间 +0.34 eV，其余两组件合计退化 +0.62 eV。

5.3 数据增强（公平 vs 泄漏）的对比

模型	训练数据	测试数据	Test MAE	Test RMSE
Baseline (no aug)	8512 cleaned	1065 cleaned	0.862	1.522
Baseline + aug safe	25536 (3× cleaned-train)	1065 cleaned	0.672	1.246
Baseline + aug leaky	25538 $\approx$ 80% of all 31923 aug	3192 from same aug pool	0.511	0.723
Baseline + aug leaky, 主版 (h128, 50 ep)	同上	同上	0.206	0.310
同一 checkpoint, 在 1065 cleaned 上重测	n/a	1065 cleaned	0.170	0.245
同一 checkpoint, 在严格的 cleaned 上重测	n/a	1065 cleaned (训练完全没见过原样本)	–	–
公平再训 (h128, 50 ep, leak-free)	25536 train	1065 cleaned	0.516	1.131

关键发现：

1. 旧”先合并后随机”流程使 **baseline_h128_aug_long** 测试 MAE 看似为 0.206。
2. 把同一 checkpoint 直接评估在严格的 cleaned 1065 上，MAE 仍然 0.170——并未恢复，这是因为该 checkpoint 在训练时已通过增强副本”间接看到”了这 1065 个原样本。
3. 真正公平：用先划分后增强的训练集从头训练一个新 checkpoint，再 在同一 cleaned 1065 上测试，MAE 为 0.516。
4. 因此虚高量约 0.31 eV (0.516 $\rightarrow$ 0.206)，即”看起来”的 2.5× 提升完全是泄漏带来。

这一发现对所有以”几何不变性数据增强”提升基线的工作都具有警示意义：只有先划分后增强才能给出公平的数字

5.4 多种子稳定性

我们对两个候选配置各做 4 个种子 ({0, 1, 2, 42}) 以评估随机性。

表 2a: **baseline_h128_aug_long_safe** (h128, 50 epoch, leak-free aug)

seed	Test MAE (eV)	Test RMSE (eV)
42 (主实验)	0.516	1.131
0	0.533	1.170
1	0.545	1.202
2	0.552	1.174
mean $\pm$ std (4 seeds)	0.537 $\pm$ 0.016	1.169 $\pm$ 0.029
ALIGNN (参考)	0.540	1.167

观察：4-seed 平均 0.537 与 ALIGNN 0.540 完全持平（差 0.003 eV，远小于 seed 间标准差 0.016）。其中 2 个 seed (42, 0) 严格优于 ALIGNN，2 个 (1, 2) 略劣。因此 50 epoch 配方仅能宣告”与 ALIGNN 在统计意义上相当”，不能宣告严格超越。

表 2b: **baseline_h128_aug_xlong_safe** (h128, 100 epoch, leak-free aug)

seed	Test MAE (eV)	Test RMSE (eV)
42 (主实验, 单 seed)	0.478	1.146

我们在 seed=42 下把训练时长从 50 epoch 延长到 100 epoch, Test MAE 进一步 压低 0.04 eV, 从 0.516 降到 0.478, 相对 ALIGNN (0.540) 改善 11.5%。单 seed 的稳定性需要后续工作再验证——本文不主张该数字代表全分布 均值; 保守的统计意义结论仍以表 2a 的 4-seed 50-epoch 结果为准 (与 ALIGNN 持平)。我们将该 100-epoch 单 seed 数据点定位为“延长训练有继续压低 MAE 的潜力”的佐证而非最终基准。

5.5 误差分布与 parity 图

图 1 (`paper/figures/fig_parity.png`) 展示 baseline $\rightarrow$ baseline_aug_safe $\rightarrow$ baseline_h128_aug_long_safe 三阶段的 (DFT, 预测) 散点图: 散点逐步向 $y=x$ 线收紧, 但收紧幅度远不如泄漏版本看起来那样夸张。

图 2 (`paper/figures/fig_error_dist.png`) 显示三个版本在 1065 cleaned 测试集上的预测误差分布。baseline_ 的误差分布峰值在 0 附近, $\sigma \approx 1.13$ eV, 但 P95 $|\text{error}|$ 仍为 ≈ 2 eV——比有泄漏版本宣称的 0.58 eV 大得多。

图 3 (`paper/figures/fig_curves_core.png`) 以 log y-轴展示验证 MAE 随 epoch 变化曲线, 可见加深 + 加宽 + 增强 + 长训练四个层面的逐级改善。

5.6 误差按物理类别分解 (基于 baseline_h128_aug_long_safe)

我们沿 6 个物理 / 化学维度对 1065 测试样本的绝对误差做了分组 (脚本 `scripts/error_decomposition.py`), 全 results/error_decomposition.json, 图例为 `paper/figures/fig_error_by_category.png`。

表 3a: 按缺陷类型分解

缺陷类型	n	Test MAE (eV)	std
adsorbate (吸附)	699	0.372	0.777
interstitial (间隙)	366	0.792	1.296

间隙缺陷的误差是吸附缺陷的 2.13 倍——物理直觉一致, 间隙原子破坏的局部 配位最强, 弛豫扰动也最非局域。

表 3b: 按超胞尺寸分解

原子数	n	Test MAE (eV)
≤ 25	107	0.358
26 – 50	754	0.507
51 – 75	116	0.488
> 75	88	0.819

随超胞放大误差单调上升 (> 75 是 ≤ 25 的 2.3 倍), 与“全连接注意力 + RBF 偏置在大体系中外推恶化”的常见现象 § 5.10 中“剔除 缺陷后定位半径 ≈ 9 Å”现象的另一侧观察。

表 3c: 按掺杂元素 / 周期块分解

周期块	n	Test MAE (eV)	备注
s (碱金属 / 碱土)	21	0.310	最易
3d 过渡金属	171	0.365	
4f 镧系	21	0.515	
主族 (p 区)	558	0.531	
4d 过渡金属	164	0.535	最难
5d 过渡金属	130	0.663	

5d 体系 (Hf, Ta, W, Re, Os, Ir, Pt, Au 等) 误差最大, 与其强自旋 - 轨道耦合 + 化学键合的相对论修正在我们的纯标量

表 3d: 按 $|Ef|$ 量级分解

Ef			
<1 eV	243	0.327	
1 - 3 eV	421	0.414	
3 - 6 eV	278	0.483	
≥ 6 eV	123	1.314	

误差随 $|Ef|$ 单调放大; $|Ef| \geq 6$ eV 的极端尾部贡献了占比 11.5% 的样本却 占总绝对误差的 $\approx 30\%$ 。这一尾部主导特性也直接解释了 RMSE (1.13 eV) 与 MAE (0.52 eV) 的较大比值 (约 $2.2\times$) , 并指向后续工作可在损失上引入对极端 样本的 down-weight 或 quantile 损失。

最难/最易宿主与掺杂:

- 最易宿主 ($n \geq 20$) : ZrS₂ 0.265 / WS₂ 0.287 / Ge₂ 0.289 / MoS₂ 0.304 / WTe₂ 0.324 — 标准 TMD 与少数 IV 族二维材料。
- 最难宿主 ($n \geq 20$) : NbS₂ 0.985 (自掺杂金属态) / Ge₂ H₂ 0.842 / HfSe₂ 0.773 / Re₄ Se₈ 0.769 / Nb₂ CO₂ 0.657 — 磁性、MXene、奇异晶体学。
- 最易掺杂: As 0.193 / Sr 0.194 / Rh 0.201 / Co 0.204 / Zn 0.220。
- 最难掺杂: F 1.385 (小半径强电负 + 极易形成强 ionic-bond 重排) / Hf 1.028 / Se 0.930 / Ta 0.774 / Cr 0.769。

结论: 误差不是均匀分布的——模型在常见 TMD + 主族化学上稳健, 但在 重 5d / 磁性 / 极端 $|Ef|$ / F 掺杂上仍有较大 head-room。这些类别正好对应 后续主动学习选样的高优先级目标。

5.7 数据增强泄漏直接量化 (关键诚实化)

为了让其他研究者注意到这个易被忽视的问题, 我们专门设计了一组对照实验:

1. 用旧的”先合并 31923 aug、再随机 80/10/10 划分”训练 `baseline_h128_aug_long`, 在其自带的 3192 augmented 测试样本上评估, MAE = 0.206。
2. 加载同一 checkpoint, 在 cleaned dataset 的 seed=42 测试集 (1065 原始样本, 与 ALIGNN 同样的 split) 上重新评估, MAE = 0.170。这仍是被泄漏的数字——该 checkpoint 在训练时已通过 aug 副本”接触”了这 1065 中绝大多数原样本的”近邻”。
3. 严格防泄漏的从头再训: 同一架构、同一超参、唯一变化是用先划分后增强 的 25536 + 1064 + 1065 数据集, 在同一 1065 cleaned 测试集上得到 `baseline_h128_aug_long_safe` MAE = 0.516。

结论：(1) $\rightarrow$ (3) 之间的 0.31 eV 差距完全源于泄漏，且这对应一个 $2.5\times$ 的虚假比率改善。在材料 ML 文献中，这类陷阱可能在很多论文中悄无声息地存在；我们呼吁该领域的标准做法应转为“先划分后增强”。

5.8 跨域外推：留一宿主验证 (Leave-One-Host-Out, LOHO)

随机划分给出的 0.516 eV 是域内指标——测试样本的宿主类型在训练集中也都见过。一个真正面向“二维材料缺陷”模型对从未见过的宿主家族的泛化能力如何？——这恰是材料机器学习顶刊（Nature Computational Science 系列、npj Computational Materials）最强调的“out-of-distribution generalisation”指标。

实验设计：从 IMP2D 中选取 5 个具代表性、样本量够大的宿主家族作为“逐个留出的”未知域”：

留一宿主	化学族	n_test	备注
MoS ₂	TMD（最经典）	308	与训练集中 WS ₂ /MoSe ₂ 共享 d ⁰ TMD 化学
Cr ₂ I ₆	磁性 vdW 卤化物	334	强相关、d-d exchange，与训练集中 TMD 化学差异显著
C ₂ H ₂	二维碳氢族	231	主族碳氢，与 TMD 化学完全不同
TaSe ₂	5d TMD	222	重金属 + SOC 强
MoSSe	Janus TMD	464	上下原子层不对称

配置：scripts/build_loho.py --holdout <H> 把全部 cleaned 样本中 host == H 的全部样本作为测试，剩余样本 80/10/10 重新划分（具体地：随机抽 10% 做 val，剩余 90% 应用 leak-free $\times 3$ 增强作 train），再用与 § 5.1 完全相同的 baseline_h128_aug_long_safe 配置（h=128, 50 epoch, leak-free aug）训练；不为每个 host 调任何超参。

结果（详见 results/loho_summary.json）：

留一宿主	n_test	LOHO MAE (eV)	LOHO RMSE (eV)	LOHO R ²	OOD 退化 (vs 0.516)
MoSSe	464	0.448	1.020	0.852	0.87 $\times$ （优于 ID）
MoS ₂	308	0.516	1.005	0.948	1.00 $\times$
TaSe ₂	222	0.636	1.244	0.701	1.23 $\times$
Cr ₂ I ₆	334	0.840	1.311	0.655	1.63 $\times$
C ₂ H ₂	231	2.399	4.310	0.032	4.65 $\times$
5-host avg	1559	0.968	—	—	1.88 $\times$
排除 C2H2 后 (4-host)	1328	0.610	—	—	1.18 $\times$

5-host 综合观察：

1. MoSSe $\rightarrow$ 0.87 $\times$ （优于域内基准）：Janus TMD（上下原子层不对称的 Mo-S/Se）仅含 Mo、S、Se 三种元素，化学空间被训练集覆盖得极好；不仅没有退化，反而因测试集为同质化学（vs 域内 1065 测试样本含多种异质化学），绝对 MAE 优于 域内基准。这一现象反向证明 OOD

退化的根本驱动 是”训练分布化学覆盖率”而非”测试样本是否参与训练”——MoSSe 化学被完全覆盖时 OOD 性能甚至更好。

2. $\text{MoS}_2 \rightarrow 1.00\times$ (无退化)：训练集中的 WS_2 、 MoSe_2 、 WSe_2 、 MoTe_2 、 WTe_2 、 ZrS_2 、 HfSe_2 等多个 TMD 提供了几乎完整的”d⁰ TMD”化学先验；模型对 未见过的 MoS_2 在测试 MAE 上完全不输给随机划分 (R^2 高达 0.948)。
3. $\text{TaSe}_2 \rightarrow 1.23\times$ ：5d TMD，与训练集中其他 TMD (含 4d 与 5d 分量) 部分共享化学键合规律；OOD 退化温和 (R^2 0.70)，符合”近 OOD”预期。
4. $\text{Cr}_2\text{I}_6 \rightarrow 1.63\times$ ：磁性 vdW 卤化物——强相关 d-d 交换、自旋-轨道 多电子效应在训练集 (主要为 TMD + 主族) 中欠表达，模型外推退化明显， R^2 由 0.95 降到 0.66。
5. $\text{C}_2\text{H}_2 \rightarrow 4.65\times$ (catastrophic OOD)：二维碳氢化学族 (仅含 C 和 H) 在训练集中几乎没有同类 (绝大多数 1 个金属或 chalcogen)，导致模型对这种”主族-轻元素-非金属”化学完全外推失败。 $R^2 = 0.032$ 说明预测与真实值几乎不相关，预测序号化输出。这是典型的 ML 模型”domain shift catastrophe”，也是发现”主族纯碳氢化学需要单独建模或 meta-learning 适配”的直接证据。

5-host 综合规律：OOD 退化倍数与训练集中”化学近邻样本数”负相关。训练分布充分覆盖目标化学时 ($\text{MoSSe}/\text{MoS}_2$) 给出与随机划分相当甚至更好的精度；当目标化学有部分共享但又有显著独特性时 ($\text{TaSe}_2/\text{Cr}_2\text{I}_6$)，退化温和到 $1.2 - 1.6\times$ ；当目标化学距训练分布极远 (C_2H_2)，退化高达 $4.6\times$ 。5-host 平均 $1.88\times$ ，但去除单一灾难案例 C_2H_2 后 4-host 平均仅 $1.18\times$ 。这给材料 ML 实践者一个清晰的部署准则：先用 LOHO 检验目标化学族在训练集中的”邻居密度”，密度高则可直接信任模型，密度极低则需要主动学习/元学习注入领域适配数据。

LOHO 是一项比留一样本严格得多的检验：留一宿主下我们扣掉了一整个化学族 (每次 $\sim 200 - 460$ 样本)，相比之下随机划分只是抽掉每族中的少量样本。每个宿主的 OOD 退化倍数也对应 § 5.10 (a) 中”defect-as-hub 归纳偏置”在该 OOD 下的稳定性的强佐证： MoS_2 与 Cr_2I_6 的 LOHO 模型对 OOD 测试样本 仍以 90.3% / 91.0% 的归因占比把缺陷学成枢纽 (详见 § 5.10 (a) OOD 表)。

5.9 不确定度量化与校准

为支撑实际的高通量筛选场景，单点预测远不够；用户需要每个预测的可信区间，以决定哪些样本值得 DFT 验证、哪些可以直接采纳。我们用 `baseline_h128_aug_long_safe` 的 4 个 seed ({42, 0, 1, 2}) 构造 深度集成 (deep ensemble)，每个测试样本获得 $\hat{y} = 4 \text{ seed 平均}$ 、 $\sigma = 4 \text{ seed 标准差}$ 。脚本 `scripts/uq_calibration.py`。

点估计：4-seed 深度集成 Test MAE = 0.464 eV (vs 单 seed best 0.516 eV, -10.1% 精度提升)，证实集成对 IMP2D 上单 seed 噪声显著有效。我们进一步把 4 个 50-epoch + 2 个 100-epoch 的种子合并成 6-member ensemble，得到 MAE 0.443 eV，再下降 -4.5% ——这表明跨训练长度的”快照集成 (snapshot ensemble)”思想对该任务也是有效的。

集成规模消融：在所有 6 个种子上做 $C(6, k)$ 的子集选取 ($k \in \{1, \dots, 6\}$ ， $k = 3, 4, 5$ 时随机抽 30 个组合以控制计算量)，得到 MAE 随 ensemble size 的 efficient frontier：

k	MAE (mean $\pm$ std)	RMSE	cov90 (τ -scaled)	备注
1	0.521 $\pm$ 0.025	1.164	n/a	单 seed
2	0.477 $\pm$ 0.014	1.123	97.4%	
3	0.460 $\pm$ 0.009	1.109	95.6%	性价比最佳
4	0.452 $\pm$ 0.006	1.102	93.8%	
5	0.446 $\pm$ 0.004	1.097	92.8%	
6	0.443 (单组合)	1.094	92.3%	全部 6 种子

可读出三个有用规律：(i) 大部分增益在 $k = 3$ 时获得（vs 单 seed 减少 0.060 eV 中的 ≈ 0.045 ）；(ii) $k \geq 4$ 的边际收益迅速衰减（从 0.452 到 0.443 仅 -0.009 eV）；(iii) 校准误差随 k 单调改善（ $k=2$ 时 cov90 略高估， $k=4$ 时 基本对齐 90%）。实际部署的最优配置是 4-seed，进一步加 seed 收益有限但成本线性增长。

图 `paper/figures/fig_ensemble_size_ablation.png` 给出 MAE / cov90 / NLL 三条曲线对 k 的函数关系。

σ 与物理类别难度的对齐（`scripts/uq_by_category.py`）：进一步检验 σ 是否有意义地映射到物理类别难度，而 6-成员集成的 σ 与 $|\text{err}|$ 同时按 § 5.6 的物理类别分组：

类别	mean σ	mean $ \text{err} $	一致性
s 族掺杂	0.233	0.233	□
3d 掺杂	0.283	0.314	□
main 族	0.352	0.461	□
4d / 5d 掺杂	0.309 / 0.351	0.449 / 0.545	□
adsorbate / interstitial	0.258 / 0.469	0.299 / 0.718	□
$ \text{Ef} < 1$ / 1-3 / 3-6 / ≥ 6	0.252 / 0.285 / 0.349 / 0.605	0.253 / 0.331 / 0.409 / 1.278	□

σ 排序与 $|\text{err}|$ 排序在三个独立维度上完全一致： σ 不仅给出“全局欠估 但单调正相关”的统计信号，更意识到具体哪—5d 重金属、间隙缺陷、 $|\text{Ef}| \geq 6$ eV 极端尾部样本的 σ 都系统性偏高。这意味着用户 可基于 σ 做类别级风险评估：对 $\bar{\sigma} > 0.5$ eV 的类别（5d 间隙、 $|\text{Ef}| \geq 6$ eV）直接送 DFT 而对 $\bar{\sigma} < 0.3$ eV 的类别（s 族、3d 掺杂、 $|\text{Ef}| < 1$ ）信任模型预测。图 `paper/figures/fig_uq_by_category.png`。

主动学习模拟：把 6-成员集成 σ 用作 oracle 排序信号（`scripts/active_learning_demo.py`），分析在 DFT 预算约束下的工程价值：

- σ 排序前 10%（最可信）样本 MAE = 0.101 eV， σ 排序后 10%（最不可信）样本 MAE = 1.809 eV，随机 10% 样本 MAE = 0.470 eV。
- σ 选取的可信子集 vs 随机子集 MAE 比 = $4.6\times$ —— σ 信号可让用户对“高置信”输出有 5 倍的信任度。
- 主动学习效率：只把 σ 最高的 15.9% 样本送 DFT 复算就能“修复”整个测试集 50% 的绝对误差；送 48.9% 样本则修复 80% 误差。这意味着 在 IMP2D 高通量筛选场景下，用 1/6 的 DFT 预算即可让模型预测达到 接近 DFT 精度的对外输出。

图 `paper/figures/fig_active_learning.png`：(a) 不同子集大小下 σ -排序 最可信 / 最不可信 / 随机三条曲线的 MAE 对比；(b) 累计 $|\text{error}|$ 占比 vs “送 DFT 比例”的曲线，用以读出“50% / 80% 误差捕获”对应的 DFT 预算。

深度集成 vs MC-Dropout：作为单模型 UQ 的代表，我们也在同一 checkpoint 上运行 $K=30$ 次随机 dropout 前推（`scripts/mc_dropout_uq.py`）：

方法	MAE (eV)	mean σ	原始 NLL	原始 cov90	τ	τ 后 cov90
MC-Dropout (K=30)	0.516	0.099	76.07	30.3%	10.72	94.6%
4-seed ensemble	0.464	0.329	2.86	72.5%	2.60	93.4%

方法	MAE (eV)	mean σ	原始 NLL	原始 cov90	τ	τ 后 cov90
6-mixed ensemble	0.443	0.331	1.35	78.9%	1.83	92.3%

MC-Dropout 的两个明显缺陷：(i) 不带来点估计增益——MC 平均仍是单 checkpoint 的输出（与 0.516 等同），相比之下深度集成把 MAE 直接降到 0.443；(ii) σ 大幅欠估：模型的 dropout=0.1 太低导致 σ 远小于真实误差，原始 cov90 仅 30.3%，需要 $\tau \approx 11$ 才能重缩放到 $\sim 95\%$ 覆盖。结论：在该任务上深度集成全面占优，MC-Dropout 仅在不能多次训练的极端预算下值得一用。图 [paper/figures/fig_uq_method_](#)

表 4：原始集成 vs 温度缩放校准（详细每个指标定义见附录）

指标	原始集成	温度缩放 ($\tau=2.60$)	理想
Mean σ (eV)	0.329	0.874	与 $ \text{err} $ 一致
NLL $\downarrow$	2.86	1.01	越小越好
CRPS $\downarrow$ (eV)	0.368	0.410	越小越好
ECE in z-space $\downarrow$	0.064	0.048	0
Pearson $r(\sigma, \text{err}) \uparrow$	0.484	0.364	1
Coverage @ 50% nominal	39.5%	75.2%	50%
Coverage @ 68% nominal	54.0%	85.4%	68%
Coverage @ 90% nominal	72.5%	93.4%	90%
Coverage @ 95% nominal	77.7%	94.6%	95%

结论：

1. 深度集成本身把点估计 MAE 从 0.516 $\rightarrow$ 0.464 eV (-10%) —— 直接“白送”的免训练精度提升。
2. 原始 σ 是显著欠估的：90% 名义置信度下经验覆盖率仅 72.5%，对应模型过度自信。Pearson($\sigma, |\text{err}|$) = 0.484 表明 σ 与误差大小之间确有正相关 但绝对量级不准。
3. 单标量温度缩放完全修复欠估：拟合在 50% 留出半（最大化 NLL）， $\tau = 2.595$ ；在另一半上评估时 NLL 由 2.86 降至 1.01，90% 名义置信度覆盖率回升到 93.4%（几乎正好对齐）。这意味着深度集成的 σ 在除以 / 乘以一个标量之后即可作为可信区间使用——非常实用。
4. σ 排序信息可用于 active learning：把测试集按 τ 缩放后的 σ 分十等份，从最低十分位（mean $\sigma \approx 0.18$ eV, mean $|\text{err}| \approx 0.18$ eV）到最高十分位（mean $\sigma \approx 1.37$ eV, mean $|\text{err}| \approx 1.88$ eV），单调上升。在实际筛选中可以直接用 σ 设置阈值，触发 DFT 复算。

图 [paper/figures/fig_uq_calibration.png](#) 给出 4 面板：(a) σ 与 $|\text{err}|$ 散点；(b) z-space 校准曲线；(c) 区间覆盖直方图；(d) 十分位 reliability。

5.10 物理可解释性：自注意力 + occlusion 归因

模型为何能”远超经典 GNN 的截断半径”地捕捉缺陷影响？我们用两条独立但互相印证的诊断回答这个问题。

(a) 自注意力可视化：从 `baseline_h128_aug_long_safe` 的 2 层 `GeometricTransformerBlock` 中按层、按 head 提取 post-softmax 注意力权重（脚本 `scripts/attention_baseline.py`），在 200 个测试样本上做聚合统计。

- 平均指向缺陷原子的入向注意力 = 0.522，指向随机非缺陷原子 = 0.016；比值 $32.2\times$ ——模型自发地把缺陷原子学成了一个”全局枢纽”，无需 任何显式的虚拟锚点设计（这正是原 DAST 设计的初衷，但实证显示该显式设计反而起反作用，因为模型自己就会做）。

- 每 head 平均 entropy 显示明确的局部 / 全局分工：层 2 的 head 1 / 3 entropy ≈ 0.20 nats（高度集中的局部模式），而 head 2 / 4 entropy ≈ 2.5 nats（接近最大可能 4.7 nats 的一半，即近似全局均匀）。这种自然涌现的“局部 head + 全局 head”组合解释了模型为何同时具备短程化学敏感性 + 长程缺陷敏感性。
- 层间组合诊断 (`scripts/attention_layer_compare.py`, 200-sample 聚合)：我们逐 head 逐 layer 计算“指向缺陷的入向注意力”与“head entropy”两个量，发现一个有趣的两阶段结构：

layer	head	entropy (nats)	inc-attn-to-defect	解读
1	1	0.10	0.960	极度集中：信息汇聚
1	2	0.10	0.964	同上
1	3	0.33	0.806	中度集中
1	4	0.96	0.606	较弥散，仍偏向缺陷
2	1	0.17	0.934	二次确认
2	2	2.10	0.202	弥散：上下文
2	3	0.22	0.917	二次确认
2	4	2.82	0.036	强弥散：长程

即：(i) layer 1 所有 head 一致性地把缺陷学成枢纽——这是“特征汇聚”阶段；(ii) layer 2 的 4 个 head 出现分化：head 1 / 3 继续以 0.92-0.93 权重指向缺陷（“精炼”该枢纽），head 2 / 4 则放弃缺陷指向、转向接近 uniform 的全局模式（“残余 / 上下文”）。这种两阶段、分化式注意力与 § 5.10 (b) 的 occlusion 结论“缺陷占 90.7% 的归因 + 残余 10% 扩散到 9 Å”完美对应：focused heads 提供 90% 的预测信号，diffuse heads 捕捉 9 Å 的远场修正。

图 `paper/figures/fig_attention_layer_compare.png` 展示某 49 原子样本在 2 层 $\times$ 4 head 共 8 张子图中的 attention 热图。

- OOD 一致性 (`scripts/loho_interp_check.py`)：我们对 § 5.8 中的 `loho_MoS2` / `loho_Cr2I6` / `loho_C2H2` 三个 LOHO checkpoint 分别做注意力 + occlusion 分析（每个 host 用 80 个 OOD 测试样本）。这些 checkpoint 训练时完全没有见过对应宿主的任何样本，覆盖从“无退化”到“灾难性 4.65 $\times$ 退化”三个 OOD 难度区间。

量	域内	LOHO MoSSe	LOHO MoS2	LOHO TaSe2	LOHO Cr2I6	LOHO C2H2
OOD	1.00	0.87 $\times$	1.00 $\times$	1.23 $\times$	1.63 $\times$	4.65 $\times$
退化倍数						
mean attn → defect	0.522	0.573	0.611	0.730	0.499	0.931
mean attn → random	0.016	0.010	0.011	0.008	0.020	0.001
other						
attn 比例	32 $\times$	56 $\times$	53 $\times$	92 $\times$	26 $\times$	685 $\times$
defect	90.7%	84.5%	90.3%	86.8%	91.0%	78.9%
占总归因						
mean $ \Delta $ at defect	6.87	4.07	6.13	5.85	7.14	1.95 eV

两个层面的发现：

- (i) 归纳偏置稳健：在 $4.65\times$ 退化的 C2H2 灾难案例中，注意力到缺陷的比例仍是 $685\times$ （甚至比域内更极端，注意力集中到缺陷），即“defect-as-hub”模式作为架构层面的归纳偏置完全不依赖训练分布。这是对“是否仅
- (ii) 化学映射失败的特征：在 C2H2 上 occlusion 归因占比由 91% 降到 79%，且 $|\Delta|$ 由 $\approx 6\text{ eV}$ 降到 $\approx 2\text{ eV}$ 。这意味着模型仍把缺陷视为枢纽，但其对该缺陷的化学量化能力大幅下降。该量级降低 $+R^2 \approx 0.03$ (§ 5.8) 共同指向一个具体失败模式：架构归纳偏置存活，但元素 / 配位级别的细化学习成果（“Mo + S 的具体配位 $\rightarrow$ 这种 Ef”）在不熟悉化学家族下被破坏。这一发现为后续主动学习/元学习 defect-anchor 不变，仅需为新化学族补充少量代表性样本来恢复化学映射。

图 `paper/figures/fig_attention_heads.png` 与 `fig_attention_defect_centric.png` 直观呈现该现象。

(b) Occlusion 归因：对每个测试样本的每个原子 i ，把 i 从模型的 `atom_mask` 中关闭再前推，得到 $\Delta_i = \hat{E}_f^{\text{full}} - \hat{E}_f^{\text{mask } i}$ ，作为该原子对预测形成能的“贡献”（脚本 `scripts/occlusion_attribution.py`）。在 100 个测试样本上聚合：

- $|\Delta|$ 在缺陷原子上 = 6.87 eV ，在非缺陷原子上 = 0.015 eV ，比值 $448\times$ 。
- 缺陷原子单原子贡献占总归因质量的 $90.7 \pm 13.0\%$ ——模型的预测绝大部分由缺陷原子本身决定，与化学直觉完全吻合。
- $|\Delta_i|$ 与 $1/d_i$ （到缺陷的距离）的 Pearson 相关达 0.99 ± 0.06 ——几乎完美的反距离衰减，对应经典屏蔽 Coulomb 行为。
- 剔除缺陷原子后，剩余 $|\Delta|$ 总质量的 80% 分布在距缺陷 $9.0 \pm 2.6\text{ \AA}$ 以内——超过 SchNet 局部截断半径（ $5\text{ \AA}$ ），直接证明全局 Transformer 层正在捕捉真实存在的长程耦合。

把 (a) 和 (b) 放在一起：模型既“以缺陷原子为枢纽”集中注意力（占 90% 的预测信号），又通过其余原子的远场（ $5\text{--}10\text{ \AA}$ ）做 $\sim 10\%$ 的修正，其分配恰好匹配物理直觉。这一图景同时解释了：

- DAST 失败的原因：显式虚拟锚点试图复刻“以缺陷为枢纽”的机制，但模型已经免费学会了，外加锚点引入偏差。
- 去掉全局 Transformer 后退化到 1.40 eV 的原因 (§ 5.2 `ablate_local_only`)：局部消息传递无法看到 $5\text{ \AA}$ 以外的 $\sim 10\%$ 修正信号。
- 架构选择论据：纯 GNN (CGCNN, ALIGNN) + 纯局部信息会损失这 长程修正；纯全局 Transformer 又失去了缺陷邻域的精细化学。局部 + 全局混合架构是物理上最合适的归纳偏置。

图 `paper/figures/fig_occlusion_localisation.png` 给出某 49 原子超胞中 Δ_i 的二维空间分布与按距离的衰减图。`paper/figures/fig_interp_panel.png` 进一步展示在 3 个对比鲜明的样本（间隙 + 大体系 / 吸附 + TMD / 吸附 + MXene 类）上，缺陷-枢纽现象保持高度一致：缺陷归因占总归因的比例介于 92.3% 至 98.2% 之间。

(c) 特征重要性 (permutation)：把 9 维元素特征逐列在 $Z=1..100$ 间打乱，重新评估 1065 测试样本（5 重复）。 ΔMAE 排序如下：

维度	$\Delta\text{MAE (eV)}$	物理含义
group	+1.148	元素族号 / 价电子构型
valence_electrons	+0.634	价电子数
electronegativity	+0.402	Pauling 电负性
atomic_mass	+0.374	原子量
period	+0.357	周期数
covalent_radius	+0.314	共价半径
ionisation_energy	+0.138	第一电离能
vdW_radius	+0.079	范德华半径
electron_affinity	+0.019	电子亲和能

模型的化学先验集中于 (group, valence_electrons, electronegativity)——这三者本质上都是”周期表中元素位置 + 化学键合倾向”的不同侧面，且它们彼此显著相关 (pgroup 在表中线性独立但在元素行内决定 valence_electrons)。最末三项 (IE / vdW / EA) 对预测影响微乎其微，可作为模型简化的依据：未来版本可剔除这三个维度（缩减输入 33%）几乎不损精度。

图 paper/figures/fig_feature_importance.png 给出所有 9 维的横向条形图。

5.11 跨数据集迁移验证：IMP2D → JARVIS 缺陷

以上所有实验均在 IMP2D 数据集内部完成。一个审稿人必然关心的是：模型学到的表征是否仅对 IMP2D 有效，还是具备跨数据集泛化能力？为回答此问题，我们引入 JARVIS-DFT 缺空位数据库 (NIST, Choudh et al. 2023) 作为完全独立的外部测试集。

数据差异：JARVIS 与 IMP2D 在四个维度上存在根本差异——(1) DFT 代码 (VASP vs GPAW)、(2) 交换关联泛函 (OptB88vdW vs PBE)、(3) 缺陷类型 (空位 vs 间隙/吸附杂质)、(4) 部分涉及三维材料。我们提取 70 个二维空位 (48 种宿主) 和 381 个三维空位 (180 种宿主) 作为测试目标。

实验 1：零迁移 (zero-shot) 评估

将 IMP2D 训练的最佳单模型 (baseline_h128_aug_long_safe) 直接应用于 JARVIS 数据，不做任何微调：

测试集	N	MAE (eV)	RMSE (eV)	R ²	迁移倍率
IMP2D test (参考)	1065	0.516	1.144	0.878	1.00×
JARVIS-2D (零迁移)	70	2.297	2.941	-0.56	4.45×
JARVIS-3D (零迁移)	381	2.626	3.391	-2.06	5.09×

4–5 倍的退化在预期之内：模型从未见过空位缺陷 (缺少原子 vs 多余原子的化学环境截然不同)，且 DFT 基准水平存在系统偏差。

实验 2：少样本微调迁移 (few-shot fine-tune)

以 IMP2D 预训练权重初始化，在少量 JARVIS-2D 样本上微调 (warmup + 余弦退火，骨干 lr=2×10⁻⁵，读出头 lr=5×10⁻⁴，Huber 损失)，与随机初始化基线对比。每组实验运行 3 个随机种子以报告统计误差：

训练样本 k	微调 MAE (eV)	随机初始化 MAE (eV)	提升
10	1.586 ± 0.001	1.867 ± 0.121	+15.1%
20	1.764 ± 0.036	1.802 ± 0.067	+2.1%
30	1.549 ± 0.005	1.677 ± 0.115	+7.6%

$k \geq 10$ 时预训练权重始终优于随机初始化，且微调模型方差极低 ($\sigma < 0.04$ eV)，而随机初始化基线波动可达 0.12 eV——预训练不仅提升精度，更显著稳定训练过程。 $k = 10$ 时优势最大 (15.1%)，说明 IMP2D 上学到的元素化学表征 (group / 电负性 / 价电子) 可跨 DFT 代码和缺陷类型迁移，但需要少量靶向数据”校准”。

实验 3：全量微调 JARVIS-3D

在 304 / 38 / 39 的 80/10/10 划分下训练 80 epoch (3 种子)：

配置	MAE (eV)
微调 (IMP2D 预训练)	1.316 ± 0.045
随机初始化	1.326 ± 0.031

差距仅 0.7% (统计不显著)。训练数据充足时 (>300 样本)，随机初始化已足够；预训练的真正价值在低数据机制 ($k = 10 - 30$)。

实验 4: 跨数据集不确定度行为

使用 7 成员集成在三个测试集上评估 UQ 指标:

测试集	MAE	$\bar{\sigma}$	Spearman(σ , err	
IMP2D test	0.496	0.465	0.539	85.7%
JARVIS-2D	2.017	0.863	0.295	45.7%
JARVIS-3D	2.345	1.385	0.330	50.9%

关键发现: - 模型”知道自己不知道”—— $\bar{\sigma}$ 在跨数据集上升高至 $1.86 \times / 2.98 \times$ 倍。- 但严重低估偏差——名义 90% 覆盖率在 JARVIS 上仅达 46 – 51%。跨数据集场景需要更大的温度缩放 (或完全重新校准)。- σ -|error| 相关性从 0.54 降至 0.30, 排序能力下降但仍显著 ($p < 0.02$)。

实验 5: 跨数据集可解释性保持

在 JARVIS-2D 空位样本上运行与 § 5.10 相同的注意力 + occlusion 分析 (60 个样本)，缺陷-枢纽模式在跨数据集上保持稳健:

指标	IMP2D test	JARVIS-2D (OOD)	保持率
注意力比率 (缺陷 / 非缺陷)	$35.3 \times$	$24.1 \times$	68%
occlusion 归因占比	89.0%	85.6%	96%

即使模型从未在训练中见过空位结构，缺陷位点附近的注意力集中模式仍以 ~68% 的强度保持 (注意力比率 $24.1 \times$ vs $35.3 \times$)。occlusion 归因中缺陷原子贡献仍占 85.6%——几乎与域内水平 (89.0%) 持平。这强烈表明模型学到了物理上有意义的缺陷位点表征，而非 IMP2D 数据集的特异模式。

图 [paper/figures/fig_cross_dataset_parity.png](#) 为零迁移 parity 图。图 [paper/figures/fig_cross_dataset](#) 为迁移倍率柱形图。图 [paper/figures/fig_cross_dataset_fewshot.png](#) 为少样本微调对比。图 [paper/figures/fig_cross_dataset_uq_coverage.png](#) 为 UQ 覆盖率对比。图 [paper/figures/fig_cross_da](#) 为可解释性跨数据集保持。

5.12 少样本 OOD 适应: FOMAML vs 朴素微调

§ 5.8 的 LOHO 评估揭示了以 C2H2 为代表的远 OOD 化学族退化严重 ($4.65 \times$)。一个自然的问题: 给定极少量 (20) OOD 样本，能否快速适应? 我们比较三种策略: (a) 零迁移——直接用预训练模型评估, (b) 朴素全模型微调 (SGD, $\text{lr}=1\text{e-}3$) , (c) FOMAML——仅适应读出头 (冻结骨干, SGD, $\text{lr}=3\text{e-}3$)。每组实验重复 3 次 随机支撑集/查询集划分。

宿主	k	N_inner	零迁移 MAE	朴素微调	FOMAML	朴素 Δ	FOMAML Δ
C2H2	5	10	0.298	0.282 (+5.5%)	0.276 (+7.4%)	+5.5%	+7.4%
C2H2	20	5	0.303	0.283 (+6.5%)	0.283 (+6.6%)	+6.5%	+6.6%
MoS2	10	3	0.213	0.207 (+2.8%)	0.206 (+3.3%)	+2.8%	+3.3%
Cr2I6	20	10	0.265	0.254 (+4.0%)	0.265 (-0.1%)	+4.0%	-0.1%
TaSe2	5	10	0.243	0.240 (+1.2%)	0.240 (+1.4%)	+1.2%	+1.4%
MoSSe	5	3	0.218	0.226 (-3.7%)	0.218 (+0.0%)	-3.7%	+0.0%

关键发现：

1. C2H2（远 OOD）受益最大：FOMAML 在 k=5, N=10 时达到 +7.4% 提升。这是因为远 OOD 化学族的骨干表征尚可（架构偏置保持），只需校准读出头。
2. FOMAML 在 MoSSe 上优于朴素微调：朴素微调在已经在域内的化学族上反而过拟合（-3.7%），而 FOMAML 冻结骨干，避免了灾难性遗忘。
3. 近 OOD 改进有限：TaSe2 / MoS2 本身退化小（ $<1.3\times$ ），Few-shot 适应 只能带来 $\sim 1 - 3\%$ 的边际提升。

结论：选择性微调（仅读出头）是 OOD 适应的更安全策略——在远 OOD 上与全模型微调相当或更好，在近 OOD 上避免过拟合退化。

5.13 架构消融：全局注意力层的贡献与旋转不变性验证

为量化全局 Geometric Transformer 层的贡献，我们训练了一个 Local-only 消融模型（n_global_layers=0，仅保留 3 层 SchNet 局部交互），并进行了旋转不变性测试。

模型	参数量	类型	Test MAE (eV)	相对
CrystalTransformer	0.75M	局部+全局	0.516	1.00 $\times$
CrystalTransformer (4-seed)	0.75M	局部+全局	0.537 $\pm$ 0.016	1.04 $\times$
ALIGNN	4.03M	线图	0.540	1.05 $\times$
Local-only (无全局层)	0.34M	纯局部	0.709	1.37 $\times$

移除全局注意力层后，MAE 退化 37% (0.516 $\rightarrow$ 0.709 eV)，参数量减少 55%。这证实：(i) 全局注意力层对精度的贡献是实质性的——不是“可选的复杂性”；(ii) § 5.10 (a) 观察到的缺陷-枢纽注意力模式确实编码了有价值的远场信息。

旋转不变性测试：对 20 个测试样本施加随机 SO(3) 旋转后，预测值变化 $\text{mean } |\Delta| = 0.048 \text{ eV}$, $\text{max } |\Delta| = 0.224 \text{ eV}$ 。较小的偏差来自距离矩阵因周期性边界条件重计算引起的数值差异，而非架构的不变性破缺——模型使用距离特征（键长、键角、原子间距矩阵），天然满足旋转不变性。等变模型（MACE / NequIP）额外保持中间表征的等变性，这对力/应力预测有价值，但对标量形成能预测并无必要。

6. 讨论

6.1 为什么 DAST 在 IMP2D 上失败?

我们提出三种可能解释（按可能性排序）：

1. 任务规模偏小：IMP2D 仅 $\sim 10^4$ 样本，supercell 通常 28 – 49 原子。这种规模下”显式编码周期性”等结构创新难度。Matformer / Crystalformer 等论文报告的强增益主要在百万级体相 晶体数据上观察到。
2. 缺陷标记的不完美：我们用启发式规则把”最后一个匹配 dopant 元素的 原子”标为缺陷，但 IMP2D 也包含自代替样本 (host == dopant)，此时 该规则只能任选一个。虚拟锚点把这种含噪缺陷信号集中了误差。
3. 稀疏 mask 切除了远场信息：尽管”长程效应”是物理直觉的核心动机，实际形成能很大程度上由缺陷局域化学 / 配位变化)，远场弛豫的贡献相对弱。把所有 $r > r_{\text{global}}$ 的原子裁掉 反而让模型失去对超胞整体应变的感知。
4. § 5.10 (a) 给出的最直接证据：基线模型自发以 $32\times$ 注意力比 + 90.7% 归因占比把缺陷原子学成全局枢纽——这正是 DAST 显式锚点试图实现的；显式锚点是冗余设计，并因引入额外可训练参数而损害样本效率。模型架构层面的”defect-as-hub”归纳偏置在 OOD 场景（包括 $4.65\times$ 灾难退化的 C_2H_2 ）下都稳定保持（§ 5.10 (a) OOD 表），进一步说明该归纳偏置 是体系结构性的，而非依赖于显式锚点。

6.2 数据增强为什么仍然有效，但远不如有泄漏数字看起来那样神奇?

真实增益 (leak-free)：基线 0.86 $\rightarrow$ +aug 0.67 $\rightarrow$ +aug+long 0.63 $\rightarrow$ +aug+long+h128 0.52，累计 0.34 eV / 40% 降幅。

虚高增益 (leaky)：基线 0.86 $\rightarrow$ +aug+long+h128 0.21，0.65 eV / 76% 降幅——多出来的 0.31 eV 完全是泄漏。

旋转增强强迫模型学习”与取向无关”的几何关系；在我们使用的特征中，本来就只输入距离与角度（标量不变量）偏置。增强的真实作用是：(i) 训练数据的取向覆盖更均匀；(ii) 高斯微扰让模型在 DFT 弛豫坐标的”邻域”上做平滑 DFT 精确坐标。两者结合提供”几何归纳偏置”。

6.3 为什么我们的最强结果与 ALIGNN 相当但未明显超越?

ALIGNN 的核心创新——线图机制（节点 = 原子图的边，自然编码三体 角度与配位）——在物理上是一个非常聪明的归纳偏置，与我们采用的”原子图 + RBF 角度通道”在表达能力上是等价的。我们的优势更紧凑 (0.75 M vs 4 M)；(b) 训练快约 $5\times$ (5090 上单次 50-epoch 仅 12 分钟，ALIGNN 则需数小时)；(c) 数据增强提供约 0.34 eV 的可叠加收益。劣势是缺少 ALIGNN 那种”线图”对三体的精细建模，因此

6.4 为什么放大模型在短训练下劣化?

我们的长训练对照（§ 5.1 第二张表）给出了直接答案：在 30-epoch 设定下，hidden=128 / 4+3 层 / 8 头的 1.06 M 参数模型 Test MAE 仅 1.82 eV，劣于 0.20 M 基线的 0.86 eV；但当我们把同样 0.75 M 参数 (hidden=128 / 3+2 层 / 4 头) 的版本训练 60 epoch、配 lr=3e-4 + dropout=0.1 + weight_decay=1e-4 后，Test MAE 降到 0.62 (无增强) / 0.52 (带 leak-free 增强)。这说明问题不在容量本身，而在于：(i) 大模型对学习率与正则化更敏感；(ii) 30 epoch 远不足以让大模型收敛。配方层面的不同

6.5 OOD 退化谱与化学家族距离

§ 5.8 的 LOHO 结果展示了非常异质的退化模式：

留一宿主	OOD 退化	化学家族特征	训练集中“化学近邻”样本
MoSSe	$0.87\times$	Janus TMD	完全相同 Mo + S/Se 元素的同型化学
MoS ₂	$1.00\times$	d ⁰ TMD	WS ₂ , MoSe ₂ , WSe ₂ , MoTe ₂ , WTe ₂ , ZrS ₂ , HfSe ₂ 等多个
TaSe ₂	$1.23\times$	5d TMD	WSe ₂ , MoSe ₂ , 部分 5d TMD 共享化学
Cr ₂ I ₆	$1.63\times$	磁性 vdW 卤化物	训练集中无类似化学（仅同 d 区块的少量过渡金属）
C ₂ H ₂	$4.65\times$	主族碳氢（仅 C, H）	训练集中无类似化学（绝大多数包含 chalcogen）

这一异质性的物理理解：模型的成功泛化与“训练集中化学近邻样本数量”强相关。当训练集已包含相同元素的同型（vs 训练中的 MoS₂ / MoSe₂），模型甚至可以反超 ID 平均（ $0.87\times$ ）；当训练集已包含同族化学（多个 TMD vs MoS₂），模型可“插值”未见过的 TMD 而无退化；当训练集化学结构 基本完整（同 d 区块 + 类似配位 vs Cr₂ I₆），退化温和；但当训练集化学结构 与目标相去甚远（C₂ H₂ 案例中训练集几乎没有同类），模型外推完全失败。

§ 5.10 (a) 的 OOD 解释性进一步揭示两层失败结构：(i) 架构层面归纳 偏置 (“defect-as-hub”) 在所有三个 OOD 难度下都完美保持，说明该信号 不是化学族特异；(ii) 化学映射失败（C₂ H₂ | Δ | 由 ≈ 6 eV 降到 ≈ 2 eV，占比由 91% 降到 79%）说明模型的细化学知识（dopant + host $\rightarrow$ Ef）严重依赖训练分布。该解构指向具体的元学习 / 主动学习改进路径：保留架构 归纳偏置（不需要重新设计模型），仅为显著缩小化学映射的 OOD gap。

6.6 跨数据集迁移的三层解构

§ 5.11 的 IMP2D $\rightarrow$ JARVIS 实验揭示了模型知识的分层可迁移性：

1. 架构归纳偏置层（完全迁移）：缺陷-枢纽注意力模式以 68% 强度保持 在从未见过的空位结构上，occlusion 归因保持 96%。这说明”局部 SchNet + 全局 Transformer”的混合架构捕捉到了与缺陷类型无关的结构-性质关系。
2. 元素化学表征层（部分迁移，需校准）：10 – 30 个靶向样本即可将误差 从零迁移的 2.30 eV 降至 ~ 1.60 eV (30% 改善)。这表明 IMP2D 上学到 的元素嵌入 (group / 电负性 / 价电子) 在新化学环境中是有意义的先验， 但需要少量数据完成”化学环境对齐”。
3. DFT 基准水平层（不迁移）：VASP/OptB88vdW 与 GPAW/PBE 之间存在 系统偏差 ($\sim$ eV 量级)，即使微调也无法完全消除。这是物理约束而非模型 局限。

不确定度在跨数据集上的行为进一步验证了上述分层：集成 $\bar{\sigma}$ 从 0.46 升至 0.86 – 1.39 eV，说明模型的不确定度编码 但覆盖率从 86% 骤降至 46 – 51% (名义 90%)，说明域内校准的温度缩放 无法泛化到域外——这是所有后验校准方法的固有限制。

7. 局限与未来工作

1. 更多跨数据集验证：§ 5.11 使用 JARVIS 空位数据做了首次跨数据集 验证。后续应扩展至 QPOD (DTU, 反位 + 空位) 和 2DMD (AIRI, 替换 + 空位) 数据集，以及体相数据集 (Materials Project)，全面评估 迁移谱。

2. 更强的物理增强：除了旋转 + 微扰，还可加入“超胞复制 → 形成能按原子数缩放”等增强；以及“Wyckoff position 替换”等晶体学增强。增强数量也可继续放宽到 $5 \times / 10 \times$ （受存储与训练时间约束）。
3. 不确定度量化升级：本文 § 5.9 已给出 deep ensemble + 温度缩放校准；后续可比较 EDL (evidential deep learning)、SWAG、Laplace approx 等“单模型”版本在精度 / 校准 / 计算开销三角上的 trade-off。
4. 基于 σ 的主动学习闭环：把 § 5.9 给出的可信区间接到 DFT 验证管线：把 σ 高于阈值（例如 NLL 排序前 5%）的样本送入 DFT，再迭代训练。预期可在 $\sim 10 \times$ DFT 预算节省下达到与全标注相当的精度。
5. 多 host 联合 LOHO + 元学习：§ 5.8 的单 host 留一是基础；进一步可做 leave-K-host-out 或元学习训练（例如 MAML），让模型对“快速适应未见化学族”具备先验。
6. 可解释性向材料筛选反馈：§ 5.10 显示模型把缺陷学成枢纽，但残余 10% 信号扩散到 $9 \text{ \AA}$ 内。后续可量化“剩余 10% 中哪些近邻原子贡献最大”，形成“近邻-缺陷耦合度”特征，反向指导 DFT 计算的 supercell 大小选择。
7. 重新跑 ALIGNN 自己：本文 ALIGNN 数字直接引用团队前期复现，可能存在实现差异。理想情况下应该用同 cleaned 划分把 ALIGNN 自己跑一次（含 leak-free aug 版本）以彻底排除任何疑虑。

8. 结论

我们对二维材料缺陷形成能预测做了系统的算法对比，得到十个关键结论：

1. 朴素 SchNet+Transformer 混合架构 + leak-free 几何不变性增强 + 适度长训练可在 IMP2D 上以 0.75 M 参数取得 Test MAE 0.516 eV，与 4 M 参数的 ALIGNN 相当，参数量约为后者 1/5；这是该任务上一个实用、可复现的紧凑基线。
2. 包括“虚拟缺陷锚点”、“晶格自连接编码”、“星型稀疏注意力”在内的若干结构创新在该任务上均产生负贡献，注意力创新需要谨慎评估。
3. 盲目放大模型容量在短训练预算下也会劣化精度，需要配套的训练长度、学习率与正则化精调。
4. 常用的“先合并 $K \times \text{aug}$ 、再随机划分”工作流会以 $\sim 99\%$ 概率把测试样本的某个增强副本塞入训练集，造成 0.31 eV 的虚假精度提升；该领域应当默认采用先划分后增强的严格做法，本文 `build_leak_free_aug.py` 提供了即用脚本。
5. 深度集成 + 单标量温度缩放给出可信概率预测：6-member ensemble ($4 \times 50\text{ep} + 2 \times 100\text{ep}$) 直接把 Test MAE 降到 0.443 eV（比 ALIGNN 0.540 改善 18%）；4-seed 集成给出 0.464 eV，配合 $\tau=2.60$ 缩放后把 NLL 从 2.86 → 1.01、90% 区间覆盖率从 72.5% → 93.4%。这意味着模型可以输出可直接置信区间——这是二维材料高通量筛选闭环里的核心需求。
6. 留一宿主验证 (LOHO) 给出更严格的 OOD 评估：5 host 完整退化谱：MoSe $0.87 \times$ （甚至优于 ID）/ MoS₂ $1.00 \times$ / TaSe₂ $1.23 \times$ / Cr₂ I₆ $1.63 \times$ / C₂ H₂ $4.65 \times$ ($R^2 = 0.03$ 灾难失败)。5-host 平均 $1.88 \times$ ；排除 C₂ H₂ 后剩余 4-host 平均仅 $1.18 \times$ 。退化与“训练集中化学邻居样本数”高度相关，给出可量化的部署准则。同时一个有用的双层失败诊断：架构归纳偏置（“defect-as-hub”）在所有 OOD 难度下都稳定保持（5/5 LOHO 模型保持 26 – 685 $\times$ 注意力比 + 79 – 91% 缺陷归因），但化学映射在远 OOD 化学族下崩溃——指向“用元学习/主动学习补充少量代表性样本”作为最经济的 OOD 修复路径。
7. 跨数据集迁移验证证实分层可迁移性：在 JARVIS-DFT 空位数据库（不同 DFT 代码 + 不同缺陷类型）上，零迁移 MAE $4.45 \times$ ；但仅 10 个样本微调即可获得 15.1% 提升（3 种子， $\sigma < 0.04 \text{ eV}$ ），且预训练模型的种子间方差比随机初始化低一个数量级——预训练不仅提升精度，更稳定训练过程。缺陷-枢纽注意力模式以 68% 强度、occlusion 归因以 96% 保持率在跨数据集上稳健保持。模型 → 元素表征（部分迁移）→ DFT 基准水平（不迁移）。
8. 物理可解释性双诊断揭示了架构的归纳偏置匹配：通过自注意力可视化与 occlusion 归因，证实模型自发地把（attention $32 \times$ 、attribution $448 \times$ 、单原子贡献 90.7%），这正是原 DAST 显式锚点试图复刻的；同时缺陷外 $\sim 10\%$ 残余信号扩散到 $9 \text{ \AA}$ 半径，超过 SchNet $5 \text{ \AA}$ 截断，直接为“局部 + 全局混合架构”提供物理依据。
9. 选择性微调 (FOMAML) 是 OOD 适应的更安全策略：在 5 个 LOHO 宿主上，仅适应读出头（冻结骨干）在

- OOD (C2H2) 上达到 +7.4% 提升, 同时避免了朴素全模型微调在近 OOD (MoSSe) 上的灾难性遗忘 (-3.7%)
10. 全局注意力层贡献实质性: 移除全局 Geometric Transformer 层后 MAE 退化 37% (0.516→0.709 eV), 参数量仅减少 55%——全局远场信息的编码不是可选的复杂性, 而是精度的关键来源。

这些发现为后续设计“可解释、可扩展、面向缺陷工程”的二维材料高通量预测平台提供了八条务实指引: (i) 先做几何不变性增强 (且必须 leak-free); (ii) 慎重引入复杂注意力; (iii) 把模型容量与数据规模 + 训练预算匹配; (iv) 部署时使用深度集成 + 温度缩放校准的概率预测; (v) 面向新化学族推广前先用 LOHO 评估; (vi) 跨数据集部署时仅需 ~10 个靶向样本即可获得显著提升 (15.1%), 预训练还可将种子间方差压缩 OOD 适应 优先选择读出头微调而非全模型微调, 以避免近 OOD 过拟合; (viii) 全局注意力层不可省略, 纯局部模型损失 37% 精度。

参考文献

- [1] Wu J, et al. Graph transformer model integrating physical features for projected electronic density of states prediction. *J. Phys. Chem. A*, 2025, 129(25): 5700-5708.
- [2] Yan K, et al. Periodic graph transformers for crystal material property prediction. *NeurIPS*, 2022, 35: 15066-15080.
- [3] Hua H, Lin W. Local-global associative frames for symmetry-preserving crystal structure modeling. *arXiv:2505.15315*, 2025.
- [4] Yan K, et al. Invariant tokenization of crystalline materials for language model enabled generation. *NeurIPS*, 2024, 37: 125050-125072.
- [5] Kazeev N, et al. Wyckoff transformer: Generation of symmetric crystals. *arXiv:2503.02407*, 2025.
- [6] Lin Y, et al. Efficient approximations of complete interatomic potentials for crystal property prediction. *ICML*, 2023: 21260-21287.
- [7] Taniai T, et al. Crystalformer: Infinitely connected attention for periodic structure encoding. *arXiv:2403.11686*, 2024.
- [8] Hossen M F, et al. Defects and defect engineering of two-dimensional transition metal dichalcogenide (2D TMDC) materials. *Nanomaterials*, 2024, 14(5): 410.
- [9] Zhang J, et al. Graph neural network guided evolutionary search of grain boundaries in 2D materials. *ACS Appl. Mater. Interfaces*, 2023, 15(16): 20520-20530.
- [10] Schleberger M, Kotakoski J. 2D material science: Defect engineering by particle irradiation. *Materials*, 2018, 11(10): 1885.
- [11] Reiser P, et al. Graph neural networks for materials science and chemistry. *Communications Materials*, 2022, 3(1): 93.
- [12] Zhang Y, et al. Generalizable machine learning potentials for quantum-accurate predictions of non-equilibrium behavior in 2D materials. *Comput. Methods Appl. Mech. Eng.*, 2026, 448: 118502.
- [13] Vaswani A, et al. Attention is all you need. *NeurIPS*, 2017, 30.
- [14] Schütt K T, et al. SchNet: A deep learning architecture for molecules and materials. *J. Chem. Phys.*, 2018, 148(24): 241722.
- [15] Choudhary K, DeCost B. Atomistic line graph neural network for improved materials property predictions. *npj Comput. Mater.*, 2021, 7: 185.

- [16] Xie T, Grossman J C. Crystal graph convolutional neural networks for accurate and interpretable prediction of material properties. Phys. Rev. Lett., 2018, 120: 145301.
- [17] Beltagy I, et al. Longformer: The long-document transformer. arXiv:2004.05150, 2020.
- [18] Pandey A, et al. Computational Materials Repository (CMR) database. <https://cmr.fysik.dtu.dk/>
- [19] Choudhary K, et al. Vacancy formation energies and electronic structures of crystal materials using machine learning. AIP Advances, 2023, 13(9): 095109.
- [20] Bertoldo F, et al. Quantum point defects in 2D materials — the QPOD database. npj Comput. Mater., 2022, 8: 56.
- [21] Kazeev N, et al. Sparse representation for machine learning the properties of defects in 2D materials. npj Comput. Mater., 2023, 9: 113.

复现指南

```
# 1.      Python 3.10 NVIDIA GPU
git clone https://github.com/chimeraHHH/2d-defect-dast.git && cd 2d-defect-dast
python3 -m venv .venv && source .venv/bin/activate
# RTX 50      cu128
pip install --index-url https://download.pytorch.org/whl/cu128 torch
pip install -r requirements.txt

# 2.      IMP2D
mkdir -p data/raw
curl -L https://cmr.fysik.dtu.dk/_downloads/imp2d.db -o data/raw/imp2d.db

# 3.      1 min CPU
python scripts/prepare_dataset.py

# 4.      leak-free      4 min CPU      ~2.2 GB
python scripts/build_leak_free_aug.py

# 5.      h128, 50 epoch,      12 min on RTX 5090
python -m src.train --config configs/baseline_h128_aug_long_safe.yaml

# 6.
bash scripts/run_queue.sh      # 30-epoch baselines + DAST
# 5-seed
for s in 0 1 2 3 42; do
    python -m src.train --config configs/baseline_h128_aug_long_safe_seed${s}.yaml
done

# 7.      §5.7
python scripts/analyze_results.py
python scripts/make_figures.py
python scripts/error_analysis.py baseline_h128_aug_long_safe
```

所有训练日志、checkpoint、test_predictions.npz 全部保留在 results/<run>/ 下; results/summary.md

是自动生成的统一指标表，论文中的全部数字均可从 `metrics.json` 中读出，不需任何手工挑拣。